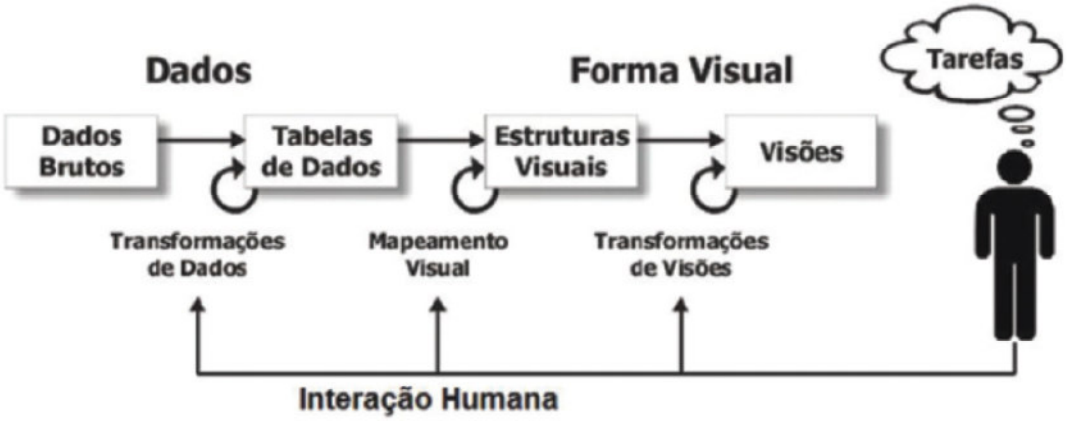
Visualização: Dados

José Gustavo de Souza Paiva

Processo de Visualização



Processo de Visualização

- Dados brutos
- Transformação para dados tabulares - estruturados

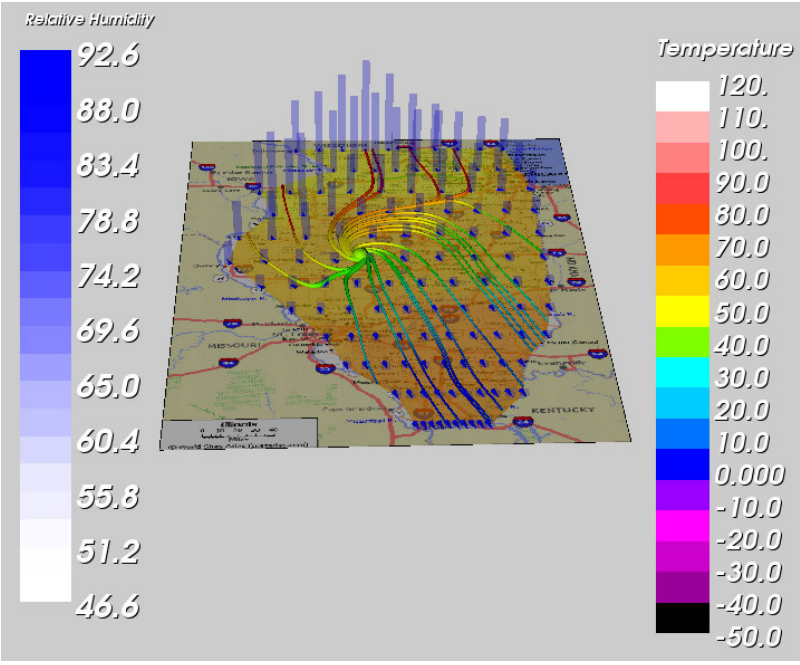
Dados

- Representam medições
  - Representação de um fenômeno do mundo real
- Exemplos
  - Temperatura
  - Pressão
  - Idade
  - Gênero
  - Nome
  - Frequência de ocorrência
  - Valor associado ao pixel de uma imagem
  - Valor de textura em determinada região de uma imagem

Dados

- Visualização Científica
  - Dados associados a um volume
  - Geralmente associados a regiões ou posições
  - Dados escalares
    - Temperatura, pressão, densidade
  - Dados vetoriais
    - Direção do vento, direção da pressão, etc.

Visualização Científica - Exemplo



www.cs.uic.edu/~jbell/CourseNotes/ComputerGraphics/Scientific%20Visualization.html

Dados

- Visualização de Informação
  - Dados estruturados ou não
    - Estruturados: tabelas de bancos de dados
    - Não-estruturados: documento de texto
  - Dados abstratos
    - Sem uma representação visual intrínseca

Modelos de Dados

- Objetos (instâncias): itens de interesse
  - Estudantes, cursos, imagem, documento, ocorrências, etc.
- Atributos (variáveis): características ou propriedades dos objetos
  - Descrição do objeto
  - Nome, idade, sexo, valor do pixel, frequência de determinado termo, etc.

Modelos de Dados

- Conjunto de dados (*data set*, coleção)
  - Conjunto de objetos e seus atributos
- Relacionamentos: como os objetos se relacionam entre si
  - Estudantes cursam cursos, documentos possuem conteúdo similar, imagens são parecidas, etc.

Modelos de Dados

- Conjunto de dados

Identificador	Atributo 1	Atributo 2	...	Atributo *d*
Instância 1	valor	valor	...	valor
Instância 2	valor	valor	...	valor
...	...	...	...	valor
Instância *n*	valor	valor	...	valor

Coleção

10

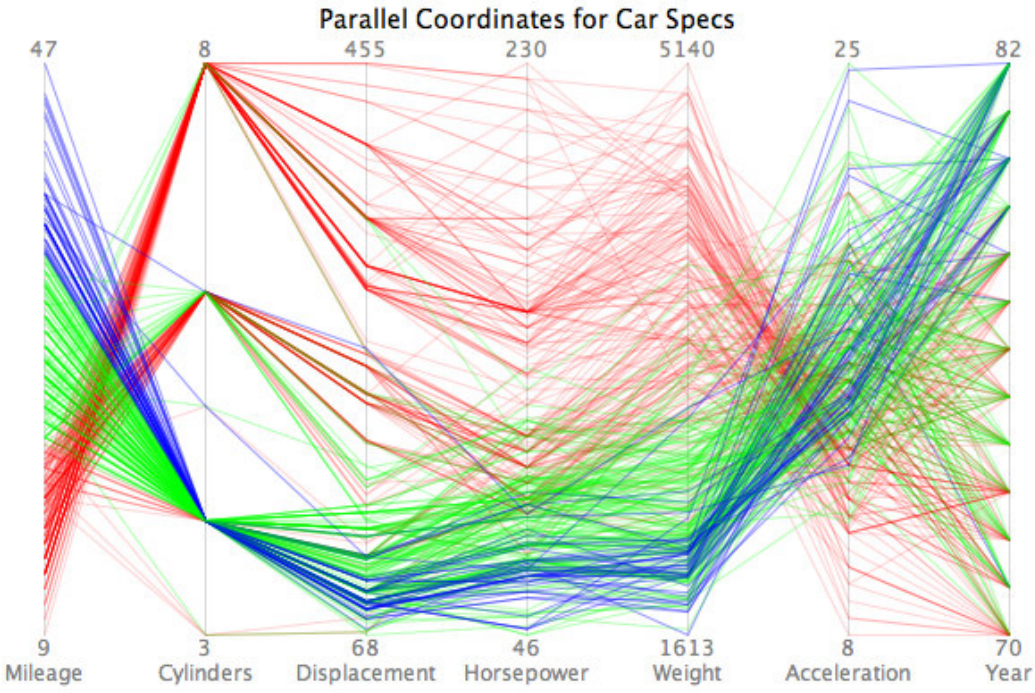
Modelos de Dados

Atributos de entrada

	Nome	Temp.	Idade	Peso	Altura
Exemplos (objetos, padrões)	João	37	70	94	190
	Maria	38	65	60	172
	José	39	19	70	185
	Sílvia	38	25	65	160
	Pedro	37	70	90	168

Figura adaptada dos slides do prof. André C. P. L. F. Carvalho – disciplina Mineração de Dados em Biologia Molecular – ICMC-USP

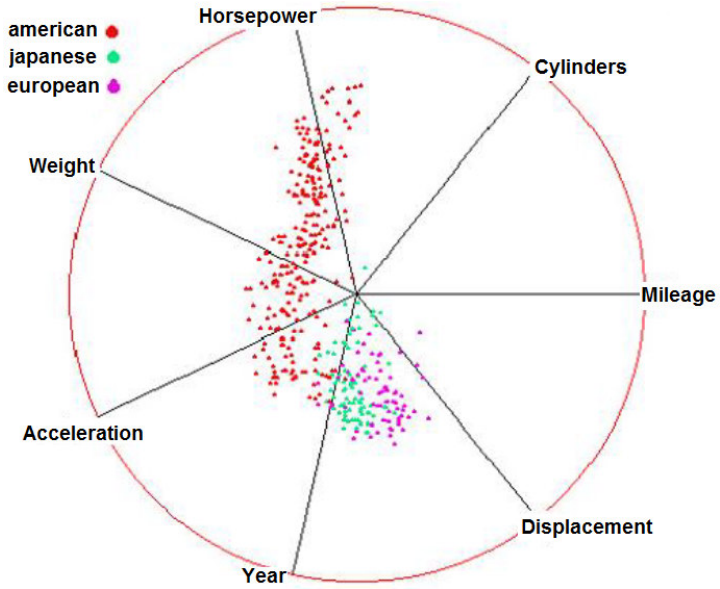
Objetos + Atributos



Wiley C., University of San Francisco

12

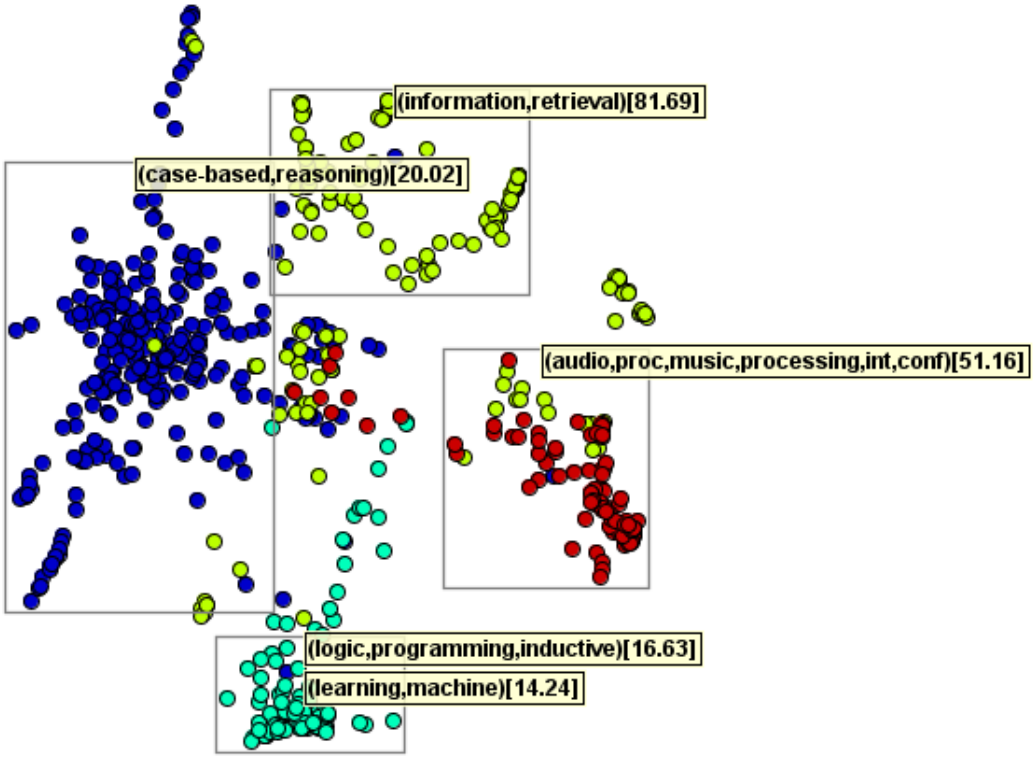
Objetos + Atributos



Hoffman, E., 1997

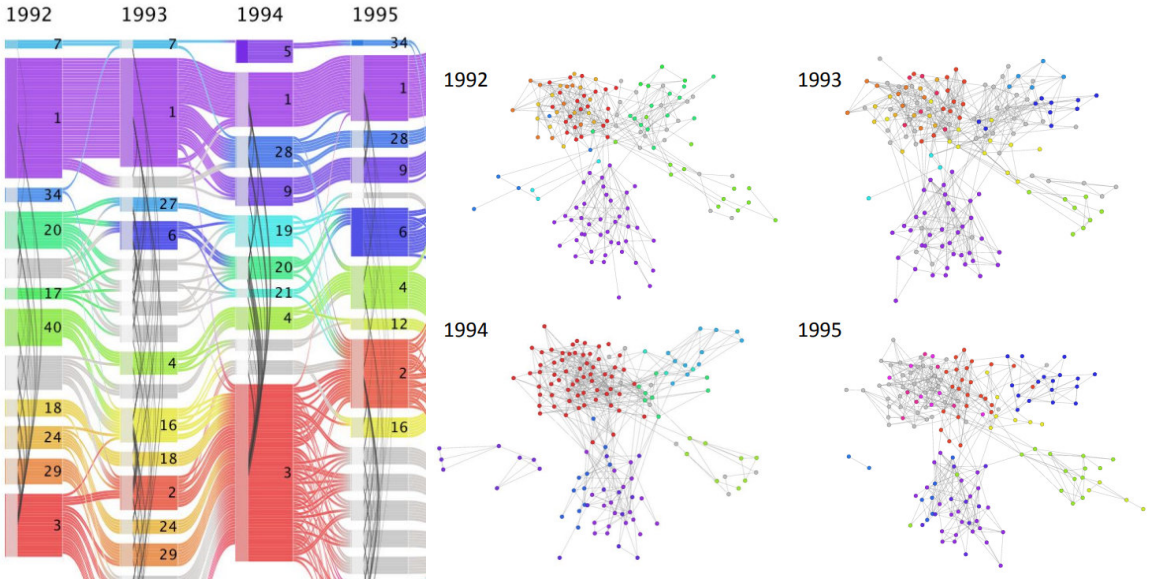
13

Objetos



14

Objetos + Relacionamentos



Vehlow, Corinna, et al. "Visualizing the evolution of communities in dynamic graphs." Computer Graphics Forum. Vol. 34. No. 1. 2015.

Agradecimentos

- Os slides a seguir são baseados nas notas de aulas da disciplina de Agrupamento de Dados da profa. Elaine Ribeiro de Faria Paiva, que gentilmente cedeu seu material para abordar esse tópico

Tipos de Atributos

- Categóricos (qualitativo)
  - Nominal
    - Valores são apenas nomes diferentes
    - Ex: gênero ({M,F} = {0,1}),
    - Ex: cor do olho ({preto,azul, verde} = {0,1,2})
  - Ordinal
    - Fornecem informações para ordenar os objetos
    - Ex: tamanho: ({pequeno, médio e grande}={1,2,3})

Tipos de Atributos

- Numéricos (quantitativo)
  - Intervalar
    - Os intervalos (diferenças) entre valores possuem significado físico/matemático, mas os valores absolutos não possuem significado proporcional intrínseco: razões não fazem sentido
    - Interpretação depende de uma unidade de medida cujo zero é arbitrário (não representa ausência)
    - Soma e subtração nos intervalos faz sentido, não nos valores absolutos
    - Exemplos: Temperatura (em graus Celsius), Datas e Horários

Tipos de Atributos

- Numéricos (quantitativo)
  - Racional
    - Razão e diferença entre valores fazem sentido
    - Zero absoluto: ausência da quantidade
    - Comparações proporcionais são úteis
    - Ex: temperatura em Kelvin, quantidades monetárias, idade e altura, peso
      - Todas possuem um zero que significa ausência

Tipos de Atributos

- Propriedades:
  - Distinção: = e ≠
  - Ordem: > e <
  - Adição: + e –
  - Multiplicação: * e /

  - Atributo Nominal: distinção
  - Atributo Ordinal: distinção e ordem
  - Atributo Intervalar: distinção, ordem e adição
  - Atributo Racional: as 4 propriedades

Exemplos

Nome	Temp	Enjôo	Mancha	Dor	Salário	Diagnóstico
João	37.7	sim	pequena	sim	1000	doente
Pedro	37.0	não	pequena	não	1100	saudável
Maria	38.2	sim	grande	não	600	saudável
José	39.0	não	pequena	sim	2000	doente
Ana	37.3	não	grande	sim	1800	saudável
Leila	37.7	não	grande	sim	900	doente

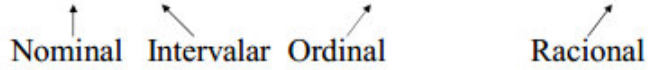


Figura retirada dos slides do prof. André C. P. L. F. Carvalho – disciplina Mineração de Dados em Biologia Molecular – ICMC-USP

Valores de um atributo

- Discreto
  - Tem um número finito de valores ou um conjunto infinito enumerável de valores
  - Ex: CEP e ID
  - **Binário**
    - Tipo especial de atributo discreto
    - Assume somente dois valores
    - Ex: true/false, sim/não ou 0/1
- Contínuo
  - Possui valores numéricos reais
  - Ex: temperatura, peso, altura

Atributos Assimétricos

- Caso especial de atributo discreto
- Alguns valores carregam mais informação, relevância ou raridade do que outros
- A presença de um valor é muito mais importante do que a sua ausência
  - Normalmente estamos interessados em saber quais objetos possuem determinada característica, e não em registrar todas as características que eles não possuem
- Pode indicar distribuição estatística assimétrica (*skewed*)

Atributos Assimétricos

- Ex: base de dados de estudantes, vetor de atributos indica se o aluno cursa ou não uma disciplina
  - Interessante saber a coincidência das disciplinas que eles fazem, e não as que eles não fazem
  - Atributo binário assimétrico
- Ex: renda
  - Diferenças em rendas altas podem ser mais relevantes
  - Distribuição é concentrada em baixos valores
  - Poucos valores extremos têm grande impacto
- Ex: número de acidentes
  - 0, 1 e 2 acidentes podem ser comuns;
  - 100 acidentes é excepcional e altamente informativo

Características de uma base de dados

- Dimensionalidade: número de atributos
  - Alta dimensionalidade → dificuldades
    - Pré-processamento: redução da dimensionalidade
- Esparsidade
  - Pode representar conjuntos de dados no qual os objetos têm característica assimétrica
  - Ex: A maioria dos atributos do objeto tem valores 0, mas o que interessa são apenas os valores não-zeros

Características de uma base de dados

- Resolução
  - Diferentes níveis → diferentes resoluções e diferentes propriedades de dados
  - Ex: calcular a variação atmosférica na escala de horas ou meses, o primeiro consegue-se ver o movimento de tempestades, já o ultimo o fenômeno não é detectável

Qualidade dos Dados

- Dados usados na mineração de dados foram coletados para outros propósitos
- Problemas nos dados precisam ser corrigidos
- Algoritmos podem tratar problemas nos dados
  - Ex: tratamento de ruídos e *outliers*

Qualidade dos Dados

- Possíveis causas de problemas nos dados
  - Erros humanos
  - Limitações dos dispositivos de medição
  - Falhas na coleta dos dados
    - O valor registrado difere do valor real
    - Omissão de objetos de dados ou valores dos atributos/inclusão de objetos inapropriadamente
    - Erros de digitação

Qualidade dos Dados

- Exemplos de problemas nos dados
  - Atributo com valores ausentes
  - Objetos espúrios ou duplicados
  - Valores incorretos

Qualidade dos Dados

- Ruídos
  - Componente aleatória de uma medida de erro
  - Distorção não sistemática de um valor ou a adição de objetos espúrios
  - Não segue um padrão
- Artefatos
  - Distorção determinística nos dados, introduzida artificialmente na aquisição/processamento
  - Ex: distorção em uma imagem de Ressonância magnética

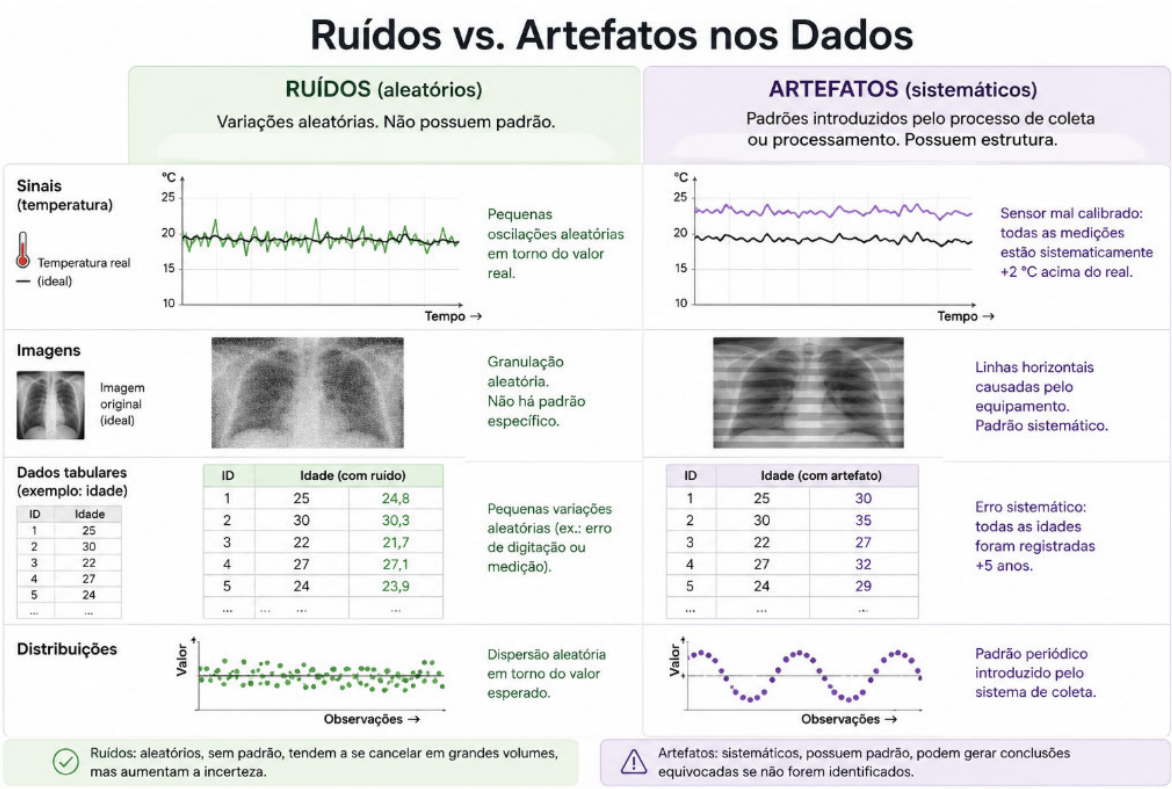
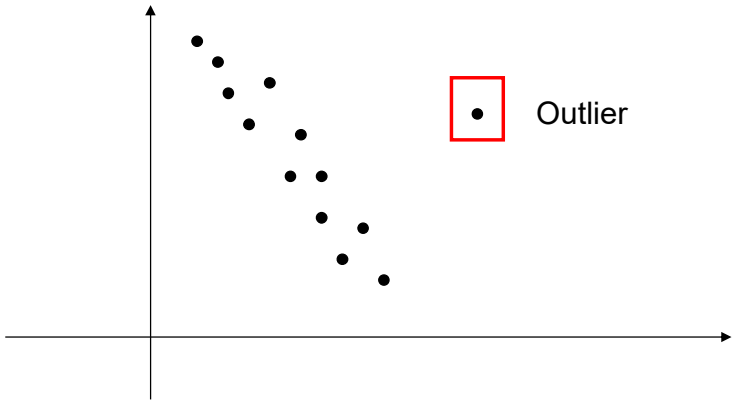


Imagem gerada no chatGPT

Qualidade dos Dados

- *Outliers*
  - Objetos de dados que tem características diferentes da maioria dos outros objetos no conjunto de dados
  - Valores de um atributo que são não usuais em relação aos valores típicos para aquele atributos
  - Em alguns casos, os *outliers* podem ser de interesse
    - Ex: detecção de fraudes

Qualidade dos Dados



Qualidade dos Dados

- Valores Ausentes
  - Não é incomum objetos terem valores ausentes para um ou mais atributos
  - Causas
    - Informação não coletada
    - Atributo não é aplicável a todos os objetos
    - Atualização dos dados
    - Problema na coleta

Qualidade dos Dados

- Estratégias para lidar com valores ausentes
  - Eliminar os objetos ou atributos com valores ausentes
  - Estimar os valores ausentes
  - Ignorar os valores ausentes
  - Modificar o algoritmo para lidar com valores ausentes

Qualidade dos Dados

- Instâncias duplicadas
  - Instâncias idênticas ou que diferem de forma não significativa
    - Ex: uma pessoa aparece duas vezes na base de dados com o campo nome com pequenas diferenças
  - Deduplicação

Qualidade dos Dados

- Deduplicação
  - Etapa 1 — Padronização
    - Colocar registros no mesmo formato
  - Etapa 2 — Escolha dos atributos-chave
    - Qual a informação de comparação
  - Etapa 3 — Comparação dos registros
    - Exata ou aproximada
  - Etapa 4 — Definição de limiar
    - Quão parecidos registros podem ser
  - Etapa 5 — Resolução da duplicata

Pré-processamento de dados

- Pré-processamento
  - Tornar os dados mais adequados para a tarefa de mineração/visualização
  - Objetivo: melhorar os processos de análise com relação a tempo, custo e qualidade

Pré-processamento de dados

- Pré-processamento
  - Diferentes técnicas
    - Agregação
    - Amostragem
    - Redução de dimensionalidade
    - Seleção de atributos
    - Discretização ou binarização
    - Transformação de variáveis

Agregação

- Combinar duas ou mais instâncias em um única instância
- Objetivo
  - Redução de dados
    - Menos memória e tempo de processamento
    - Uso de algoritmos mais “caros”
  - Comportamento mais estável
    - Quantidades agregadas tem menor variabilidade que objetos individuais
  - Desvantagem: perda de detalhes
- Ex: Agregar a soma de produtos vendidos nas cidades de uma região

Amostragem

- Selecionar um subconjunto das instâncias
- Técnica muito útil em mineração de dados
- Visão da Estatística
  - É caro e exige muito tempo obter todos os dados
- Visão da mineração de dados
  - É caro e consome muito tempo processar todos os dados

Amostragem

- Princípio básico
  - O uso da amostragem irá produzir resultados tão bons quanto usar o conjunto de dados inteiro, se a amostragem for **representativa**
  - Menor esforço computacional para processar os dados
- Amostragem representativa
  - Possui as mesmas propriedades (de interesse) da base de dados original
  - Ex: mesma média na base original e na amostra

Técnicas de Amostragem

- Principais técnicas
  - Aleatória
  - Estratificada
  - Progressiva

Técnicas de Amostragem

- Aleatória
  - Sem reposição: Cada instância selecionada é removida do conjunto de dados que constituem a população
  - Com reposição: Instâncias não são removidas da população quando são selecionadas
    - A mesma instância pode ser selecionada mais de uma vez
    - A probabilidade de selecionar um objeto se mantêm constante
    - A reposição transforma os sorteios em experimentos independentes, o que simplifica a estatística

Técnicas de Amostragem

- Estratificada
  - Usada para garantir que todas as classes do problema serão representadas
  - Variações
    - O mesmo número de instâncias de cada classe são selecionadas
    - O número de instâncias selecionadas de cada classe é proporcional ao número de instâncias da classe

Técnicas de Amostragem

- Progressiva
  - O tamanho da amostra é difícil de ser determinado
  - Solução: começar com uma pequena amostra e aumentar o tamanho da amostra até que um tamanho suficiente seja encontrado

  Como avaliar se o tamanho é suficiente?

Amostragem e Perda de Informação

- Como escolher o tamanho da amostra?
  - Amostras grandes
    - + Aumentam a probabilidade de que a amostra será representativa
    - - Eliminam muitas das vantagens da amostragem
  - Amostras pequenas
    - - Aumenta a chance de perda de informação

Técnicas de Amostragem



8000 points | 2000 points | 500 points

Imagem reitrada de Tan P., SteinBack M. e Kumar V. Introduction to Data Mining, Pearson, 2006

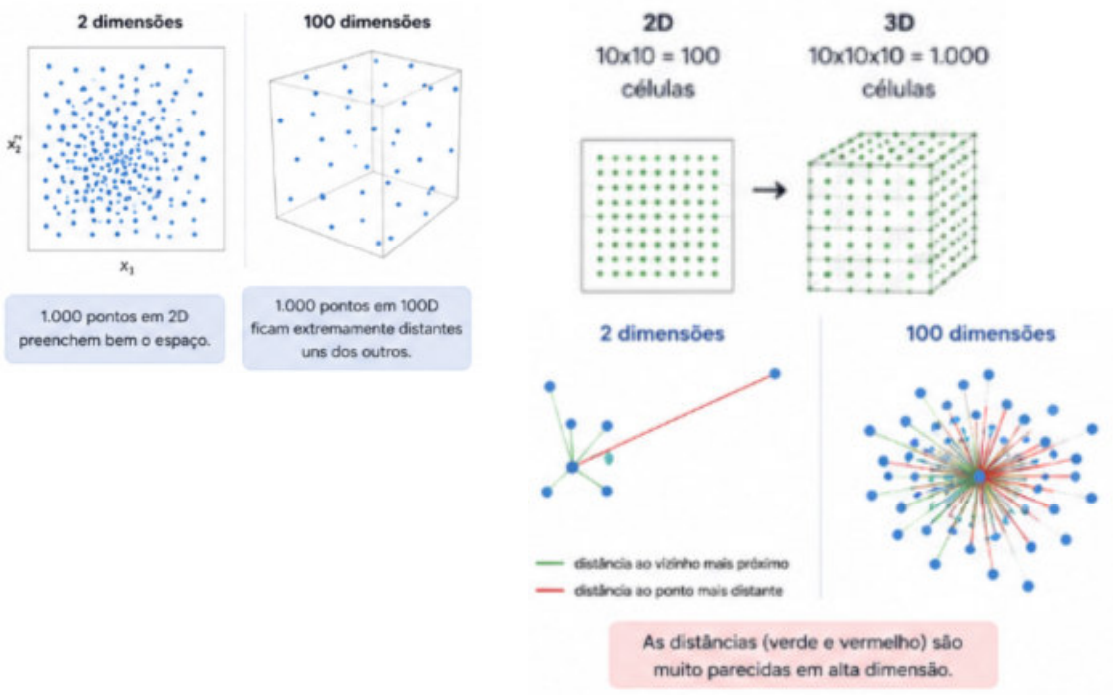
Maldição da Dimensionalidade

- Fenômeno no qual a análise dos dados torna-se mais complicada com o aumento da dimensionalidade: alto número de atributos
- Dimensão aumenta → dados mais esparsos
  - Densidade e distância entre pontos tornam-se menos significativas
  - Muitos dados tornam-se “poucos” em alta dimensão
  - Ex: 1000 pontos em 2D podem preencher bem um espaço, mas 1000 pontos em 100 dimensões ficam extremamente distantes uns dos outros
  - Dimensões “afastam” objetos uns dos outros

Maldição da Dimensionalidade

- Número de instâncias necessário para manter o desempenho cresce com o número de atributos
- Reduzir a dimensionalidade pode ser a solução para trabalhar com conjuntos de dados contendo muitos atributos

Maldição da Dimensionalidade



Redução de Dimensionalidade

- Benefícios
  - Algoritmos trabalham melhor com poucos atributos
  - Redução de atributos irrelevantes e ruídos
  - Modelo mais compreensível
  - Dados mais facilmente visualizados
  - Quantidade de tempo e memória usados pelo algoritmo de mineração de dados é reduzida

Redução de Dimensionalidade

- Transformação de Atributos
  - Reduzir a dimensão criando novos atributos que são uma combinação dos atributos antigos
- Seleção de atributos
  - Reduzir a dimensão selecionando novos atributos que são um subconjunto dos atributos antigos

Transformação de dados

- Tarefa: transformar dados
  - Conversão numérico - categórico ou vice-versa
  - Normalização
- Motivação: Algumas técnicas trabalham apenas com dados numéricos ou apenas com categóricos
- Discretizar: atributos contínuos para categóricos
- Binarizar: atributos contínuos/discretos para binário

Discretização de Atributos Contínuos

- Tarefas
  - Decidir quantas categorias: dividir os valores dos atributos em *n* intervalos, especificando *n-1* pontos de divisão
  - Decidir mapeamento: todos os valores em um intervalo são mapeados para o mesmo valor categórico
  - Representação
    - $x_0 < x \leq x_1$, $x_1 < x \leq x_2$, ... → intervalos

Discretização de Atributos Contínuos

- Discretização não-supervisionada
  - Prop. 1: Larguras Iguais
    - Dividir o atributo em um número de intervalos especificado pelo usuário (todos do mesmo tamanho)
  - Prop. 2: Frequências Iguais
    - Dividir o atributo em intervalos, de modo que cada um tenha a mesma quantidade de exemplos

Discretização de Atributos Contínuos

- Discretização não-supervisionada
  - Prop 3. Inspeção Visual
    - Determinar visualmente qual é a melhor forma de discretizar os dados
  - Prop 4: Algoritmos de agrupamento
    - Usar algoritmos de agrupamento para encontrar a melhor forma de discretizar os dados

Discretização de Atributos Contínuos

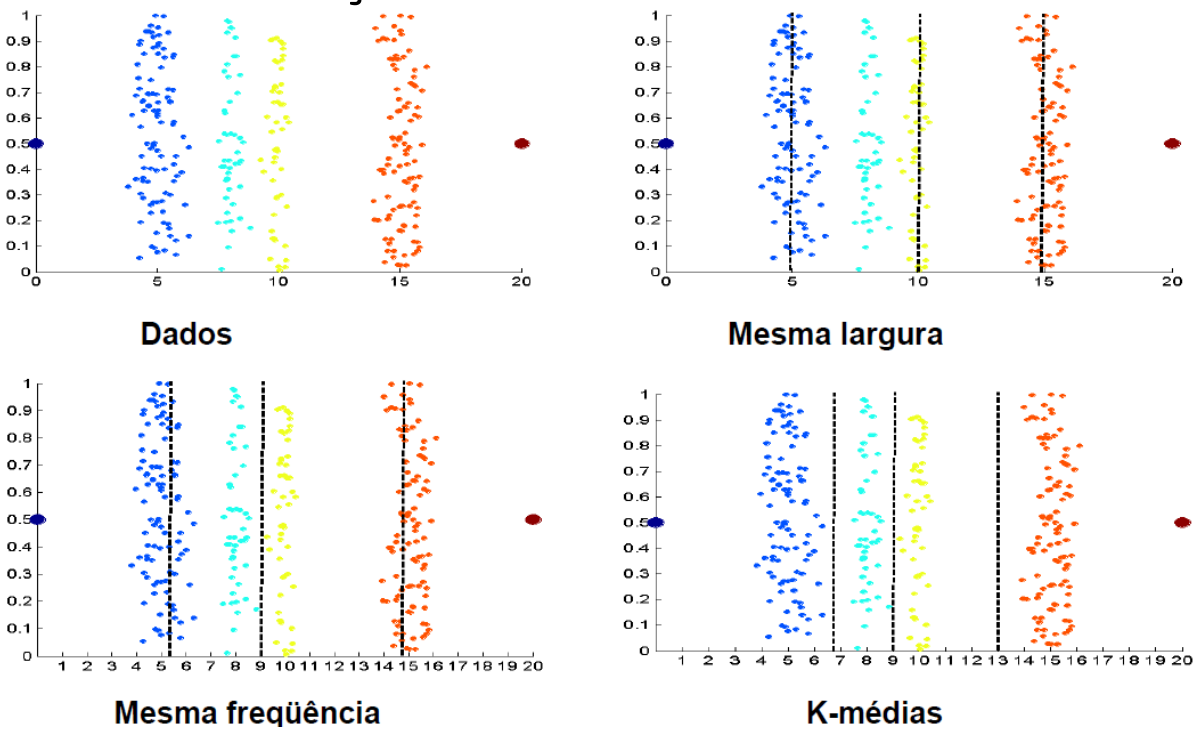


Figura retirada dos slides do prof. André C. P. L. F. Carvalho – disciplina Aprendizado de Máquina – ICMC-USP



https://mapsontheweb.zoom-maps.com/posts/population-divided/the-world-divided-in-5-equal-parts

Transformação de Atributos

- Aplicada a todos os valores do atributo
- Motivação
  - Grande variação de valores
  - Limites dos valores são muitos diferentes
  - Evitar que um atributo predomine sobre o outro
  - Propriedades estatísticas desejadas
- Tipo de transformação
  - Função simples
  - Normalização

Transformação de Atributos

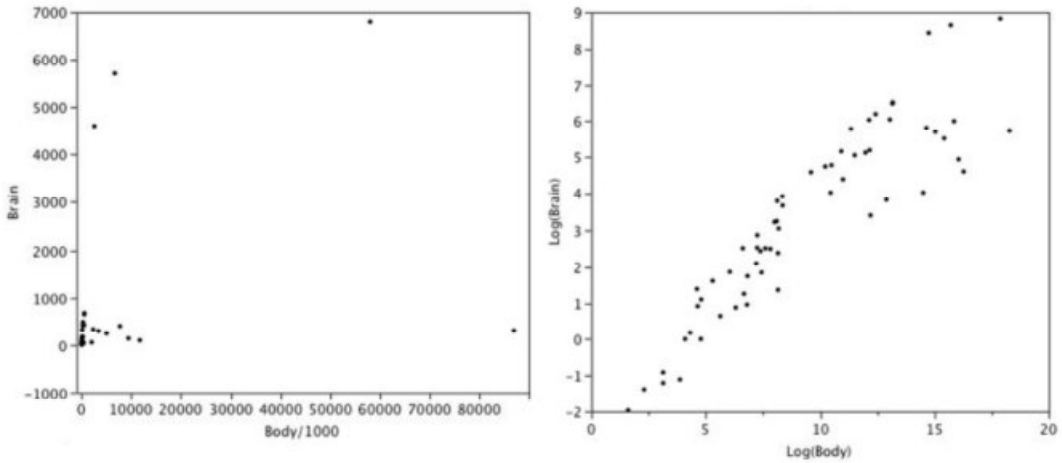
- Motivação: Exemplo
  - Comparar duas pessoas usando duas variáveis: idade e salário
    - A diferença entre salário será muito maior do que entre idade
    - A diferença entre duas pessoas será dominada pelo atributo salário

Transformação de Atributos

- Função simples
  - Uma função matemática simples é aplicada a cada valor individualmente
  - Ex: Seja x a variável
    - Exemplo de funções: x^k, log x, sen x, 1/x ou |x|

Qual função escolher: Depende do problema

Transformação de Atributos



Scatterplots do peso do cérebro do animal em função do peso do corpo

Retirado de http://rstudio-pubs-static.s3.amazonaws.com/289147_99e32d5403f942339c3fe05414ac62fd.html

Transformação de Atributos

- Normalização
  - Objetivo: fazer um conjunto de valores ter uma propriedade particular
  - Tipos de normalização
    - Reescalonamento (*normalization/min-max scaling*)
    - Padronização (*standardization/z-score*)

Transformação de Atributos

- Reescalonamento
  - Mudar a unidade de medida dos dados
  - Colocar os valores mínimos e máximos iguais
  - Como fazer
    - Adicionar ou subtrair uma constante
    - Multiplicar ou dividir por uma constante
  - Ex: converter os valores para o intervalo [0,1]

$$d' = \frac{(d - \min_d)}{(\max_d - \min_d)}$$

Transformação de Atributos

- Padronização
  - Como fazer:
    - Adicionar ou subtrair uma medida de localização
    - Multiplicar ou dividir por uma medida de escala
  - Ex: $\bar{\mu}$ é o valor médio de um atributo e S_x é o seu desvio padrão, então

$$x' = (x - \mu)/S_x$$

Cria uma variável que tem média zero e desvio padrão 1

Reescalonar vs Padronizar

- Regra geral (há exceções)
  - Intervalo natural dos dados importa: reescalone
    - Exemplo: valor de intensidade do pixel em uma imagem
    - 0 - 255
    - Limites estabelecidos
    - Posição do valor no intervalo é relevante
  - Distância em relação à média importa: padronize
    - Exemplo: rendas mensais
    - 0 (não muito comum) - infinito (sem limite físico)
    - Importante saber qual a distância do comportamento médio

Medidas de Similaridade e Dissimilaridade

- Importância: usadas em uma série de técnicas de aprendizado de máquina e visualização
- Transformação dos dados para um espaço de similaridade (dissimilaridade)
  - Em muitos casos o conjunto de dados inicial não é necessário para executar a técnica: apenas as medidas de similaridade ou dissimilaridade são suficientes
- Proximidade entre objetos refere-se à proximidade entre seus atributos

Medidas de Similaridade e Dissimilaridade

- Similaridade entre dois objetos
  - Medida numérica do quão parecidos dois objetos são
  - Objetos parecidos → similaridade alta
  - Número não negativo entre 0 (não similar) e 1 (completamente similares)
- Dissimilaridade entre dois objetos
  - É uma medida numérica do quão diferente dois objetos são
  - Objetos parecidos → dissimilaridade baixa
  - Está no intervalo [0,1] ou [0, ∞]
  - Distância é um sinônimo (tipo especial de dissimilaridade)

Similaridade e Dissimilaridade entre Atributos Simples

- 1 atributo, considerando duas instâncias *p* e *q*:

Attribute Type	Dissimilarity	Similarity
Nominal	$d = \begin{cases} 0 & \text{if } p = q \\ 1 & \text{if } p \neq q \end{cases}$	$s = \begin{cases} 1 & \text{if } p = q \\ 0 & \text{if } p \neq q \end{cases}$
Ordinal	$d = \frac{\lvert p-q \rvert}{n-1}$ (values mapped to integers 0 to $n-1$, where n is the number of values)	$s = 1 - \frac{\lvert p-q \rvert}{n-1}$
Interval or Ratio	$d = \lvert p - q \rvert$	$s = -d$, $s = \frac{1}{1+d}$ or $s = 1 - \frac{d - min_d}{max_d - min_d}$

Tabela retirada dos slides do prof. André C. P. L. F. Carvalho – disciplina Aprendizado de Máquina – ICMC-USP

Dissimilaridade entre Objetos

- Existem várias medidas de dissimilaridade
  - Diferentes medidas podem ser aplicadas a diferentes problemas
- Objetos (ou Instâncias) são descritos por *n* atributos
  - Calcular a medida de dissimilaridade usando os *n* atributos
  - Em geral, usa-se medidas de distância
- Distância
  - Medida de dissimilaridade que possui certas propriedades

Propriedades das distâncias

- Positividade
  - $d(x,y) \geq 0$ para todo x e y
  - $d(x,y) = 0$ somente se $x = y$
- Simetria
  - $d(x,y) = d(y,x)$ para todo x e y
- Desigualdade triangular
  - $d(x,z) \leq d(x,y) + d(y,z)$ para todos os objetos x, y e z

Propriedades das distâncias

- Medidas que satisfazem as 3 propriedades: métricas
- Ex. de medida de dissimilaridade que não é métrica

  Conjuntos A e B

  A – B: elementos que estão em A e não estão em B

  dist(A,B) = tamanho (A – B)

  - Não atende a 2ª parte da propriedade da positividade
  - Não atende a simetria
  - Não atende a desigualdade triangular

Propriedades da similaridade

- Propriedades
  - s(x,y) = 1 somente se x = y ($0 \leq s \leq 1$)
  - s(x,y) = s(y,x) para todo x e y

  - Não há uma propriedade análoga à desigualdade triangular para medidas de similaridade

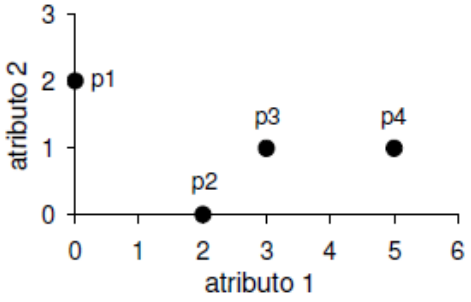
Medidas de Distância

- Distância Euclidiana
  - Distância *d* entre dois objetos x e y em um espaço *n* dimensional

$$d(x,y) = \sqrt{\sum_{k=1}^{n}(x_k - y_k)^2}$$

X_k e y_k são o k-ésimo atributo dos objetos x e y

Medidas de Distância



	atributo 1	atributo 2
p1	0	2
p2	2	0
p3	3	1
p4	5	1

matriz de distância

	p1	p2	p3	p4
p1	0	2.828	3.162	5.099
p2	2.828	0	1.414	3.162
p3	3.162	1.414	0	2
p4	5.099	3.162	2	0

Imagem retirada dos slides do prof. Ricardo J. G. B. Campello – disciplina Aprendizado de Máquina – ICMC-USP

Medidas de Distância

- Distância de Minkowski
  - Generalização da distância Euclidiana

$$d(x,y) = \left(\sum_{k=1}^{n} | x_k - y_k |^r \right)^{\frac{1}{r}}$$

  - r = 1 : distância *city block* (*Manhattan* ou L_1 norm)
  - r = 2 : distância Euclidiana (L_2 norm)
  - r = ∞ : distância Suprema (L_{max} ou L_∞ norm)

$$d(x,y) = \lim_{r \to \infty} \left(\sum_{k=1}^{n} | x_k - y_k |^r \right)^{\frac{1}{r}}$$

Medidas de Similaridade

- Medidas de similaridade para vetores binários
  - Chamadas de coeficiente de similaridade
  - Possuem valores entre 0 e 1
    - 1: objetos completamente similares
    - 0: objetos não similares
  - Comparando objetos x e y que consistem de *n* atributos binários (vetores binários)
    - f_{00} = nro de atributos em que x=0 e y=0
    - f_{01} = nro de atributos em que x=0 e y=1
    - f_{10} = nro de atributos em que x=1 e y=0
    - f_{11} = nro de atributos em que x=1 e y=1

Medidas de Similaridade

- **Coeficiente de casamento simples**

$$SMC = \frac{f_{11} + f_{00}}{f_{01} + f_{10} + f_{00} + f_{11}}$$

  - Conta as presenças e ausências igualmente
  - Ex: encontrar os estudantes que responderam de forma similar a um teste que consiste de questões true/false.

Medidas de Similaridade

- **Coeficiente de Jaccard**

$$J = \frac{f_{11}}{f_{01} + f_{10} + f_{11}}$$

  - Usado para atributos binários assimétricos
  - Não considera as coincidências de 0s

Medidas de Similaridade

- Ex:

x = (1,0,0,0,0,0,0,0,0,0)

y = (0,0,0,0,0,0,1,0,0,1)

f_{01} = 2 número de atributos em que x= 0 e y=1

f_{00} = 7 número de atributos em que x= 0 e y=0

f_{10} = 1 número de atributos em que x= 1 e y=0

f_{11} = 0 número de atributos em que x= 1 e y=1

SMC = 0 + 7/(2+1+0+7) = 0.7

J = 0/(2+1+0) = 0

Medidas de Similaridade

- Similaridade Cosseno
  - É uma medida do ângulo entre x e y
  - Se a similaridade é 1, o ângulo entre x e y é 0^0; se a similaridade é 0, o ângulo é 90^0

$$\cos(x, y) = \frac{x.y}{\| x \| \| y \|}$$

$$x.y = \sum_{k=1}^{n} x_k y_k$$

$$\| x \| = \sqrt{\sum_{k=1}^{n} x_k^2}$$

. → produto interno de dois vetores,

||x|| → é o tamanho (norma) do vetor x

Medidas de Similaridade

- Similaridade Cosseno

Ex. Sejam os vetores

x = (3,2,0,5,0,0,0,2,0,0)

y = (1,0,0,0,0,0,0,1,0,2)

x.y = 3*1+2*0+0*0+5*0+0*0+0*0+0*0+2*1+0*0+0*2 = 5

||x|| = sqrt(3*3+2*2+0*0+5*5+0*0+0*0+0*0+2*2+0*0+0*0) = 6.48

||y|| = sqrt(1*1+0*0+0*0+0*0+0*0+0*0+0*0+1*1+0*0+2*2) = 2.24

cos(x,y) = **0.31**

Medidas de Similaridade

- Similaridade Cosseno
  - Muito usado em mineração de texto
    - Documentos são vetores, cada atributo representa a frequência de ocorrência de um termo (palavra) no documento
    - Cada documento é esparso (poucos atributos não zero)

Medidas de Similaridade

- Correlação
  - Medida de relacionamento linear entre os atributos dos objetos
  - Pode também ser usada para medir o relacionamento entre dois atributos
  - Correlação muito usada na literatura → Correlação de Pearson

Medidas de Similaridade

- Correlação de Pearson
  - Considerando dois atributos x e y:

$$corr(x,y) = \frac{\text{cov}\, ariancia(x,y)}{desvio_padrao(x) * desvio_padrao(y)}$$

$$\text{cov}\, ariancia(x,y) = \frac{1}{n-1}\sum_{k=1}^{n}(x_k - \bar{x})(y_k - \bar{y})$$

$$desvio_padrao(x) = \sqrt{\frac{1}{n-1}\sum_{k=1}^{n}(x_k - \bar{x})^2}$$

Medidas de Similaridade

- Correlação de Pearson (alternativa)
  - Considerando dois atributos x e y:

$$x'_k = (x_k - \text{media}(x))/\text{desvio_padrao}(x)$$

$$y'_k = (y_k - \text{media}(y))/\text{desvio_padrao}(y)$$

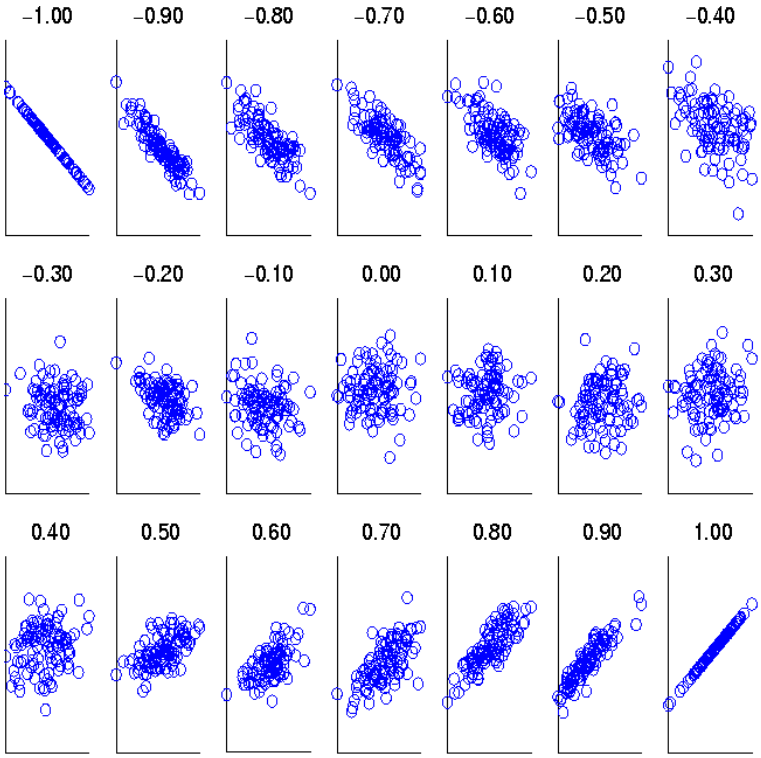
$$\text{correlacao}(x,y) = x' \cdot y'$$

Medidas de Similaridade

- Correlação de Pearson
  - Valor no intervalo [-1,1]
    - +1: objetos tem um relacionamento linear positivo

      $x_k = ay_k + b$, sendo *a* e *b* constantes
    - -1: objetos tem um relacionamento linear negativo
    - 0: não há correlação

Medidas de Similaridade



- Similaridade entre objetos x e y, cada um com 30 atributos
- Similaridade variando de -1 a 1

Tabela retirada dos slides do prof. André C. P. L. F. Carvalho – disciplina Aprendizado de Máquina – ICMC-USP

Calculando a similaridade entre objetos com diferentes tipos de atributos

Algorithm 2.1 Similarities of heterogeneous objects.

1: For the kth attribute, compute a similarity, $s_k(\mathbf{x}, \mathbf{y})$, in the range $[0, 1]$.

2: Define an indicator variable, δ_k, for the kth attribute as follows:

$$\delta_k = \begin{cases} 0 & \text{if the } k^{th} \text{ attribute is an asymmetric attribute and} \\ & \text{both objects have a value of 0, or if one of the objects} \\ & \text{has a missing value for the } k^{th} \text{ attribute} \\ 1 & \text{otherwise} \end{cases}$$

3: Compute the overall similarity between the two objects using the following formula:

$$\text{similarity}(\mathbf{x}, \mathbf{y}) = \frac{\sum_{k=1}^{n} \delta_k s_k(\mathbf{x}, \mathbf{y})}{\sum_{k=1}^{n} \delta_k} \qquad (2.15)$$

Imagem reitrada de Tan P., SteinBack M. e Kumar V. Introduction to Data Mining, Pearson, 2006

Usando Pesos

- Modificação da medida de similaridade para ponderar a contribuição de cada atributo
  - Peso (*w*) sumariza 1

$$similarida\ de(x,y) = \frac{\sum_{k=1}^{n} w_k \delta_k s_k(x,y)}{\sum_{k=1}^{n} \delta_k}$$

$$dist(x,y) = \left(\sum_{k=1}^{n} w_k \mid x_k - y_k \mid^r \right)^{\frac{1}{r}}$$

inserindo peso na distância de Minkowski

Referências

1. Rosane Minghim, notas de aula da disciplina de Visualização Computacional, USP - São Carlos
2. Torsten Muller, notas de aula da disciplina de Visualisation and Visual Data Analysis, Universitat Wien, Viena
3. Elaine Ribeiro de Faria, notas de aula da disciplina de Agrupamento de Dados