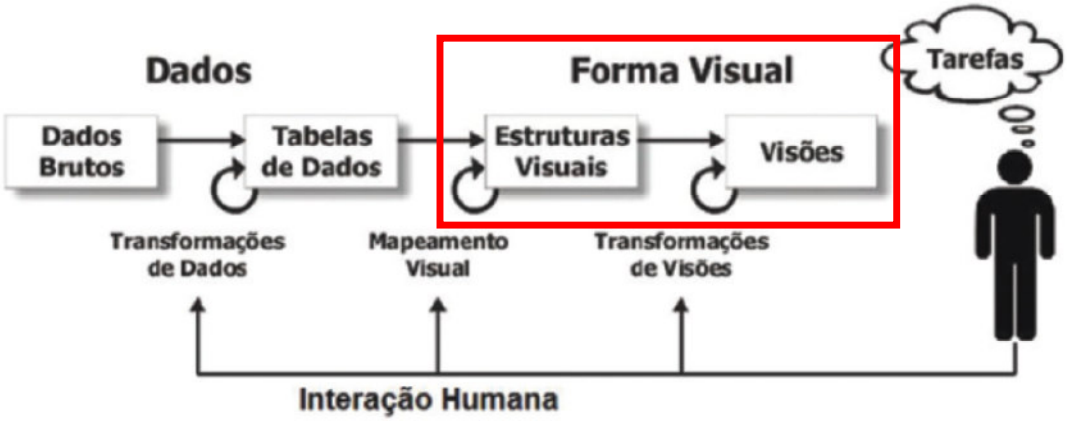
Técnicas de Visualização baseadas em atributos

José Gustavo de Souza Paiva

Processo de Visualização



Introdução

- Visualização de Informação: criar estruturas visuais para representar dados
  - Identificação de padrões e tendências
- Objetivo: processo exploratório mais rápido e com resultados melhores

- Possível categorização de técnicas
  - Técnicas baseadas em atributos
  - Técnicas baseadas em posicionamento de pontos no espaço de visualização

Técnicas baseadas em atributos

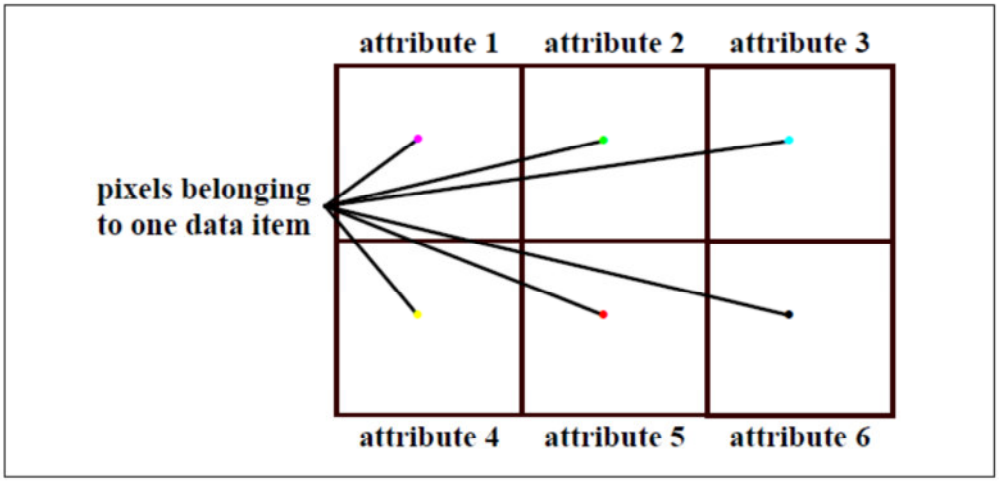
- 4 grupos de técnicas baseadas em atributos[1]:
  - Pixels
  - Transformações geométricas
  - Ícones
  - Hierarquias

Técnicas baseadas em pixel

- Cada valor de atributo de cada instância da coleção é mapeado para um “pixel” colorido
- Valores de atributos diferentes mapeados para áreas diferentes
- Objetivo: arranjar os pixels de forma a facilitar a extração de conhecimento
  - Diferentes arranjos para diferentes propostas
- Ideia: bom arranjo facilita a descoberta de agrupamentos e correlações entre os atributos

Técnicas baseadas em pixel

- Esquema:
  - *m* atributos: *m* partições



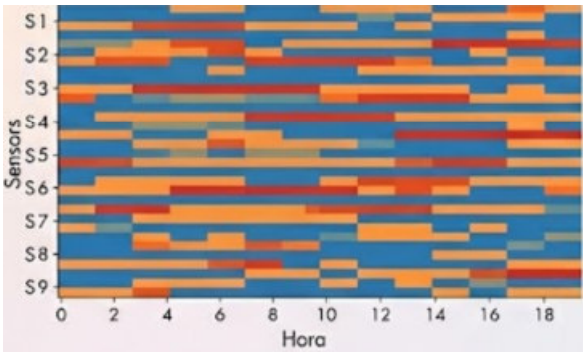
Retirado de [1]

Técnicas baseadas em pixel

- Visualização independente de consulta
  - Ordenação de instâncias de acordo com determinado(s) atributo(s)
  - Útil quando os dados possuem atributos com ordenação natural
    - Tempo, Posição geográfica, idade, renda
  - Ordenação preserva relações relevantes entre instâncias
  - Proximidade entre instâncias na visualização passa a ter significado
  - Isso favorece a identificação visual de padrões, tendências e anomalias

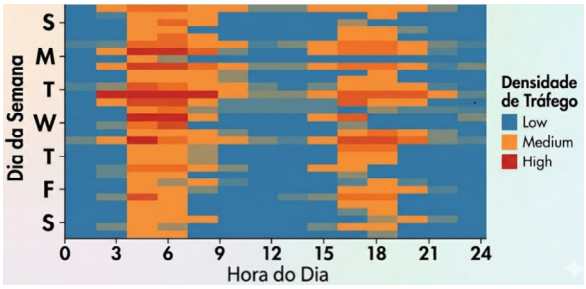
Técnicas baseadas em pixel

- Exemplo: visualização temporal de sensores de tráfego



Layout 1: Cada linha é a medição de um sensor, medindo um dia aleatório: ordem vertical segue o ID dos sensores

Layout 2: Cada linha é a medição de um sensor: ordem vertical segue dias da semana

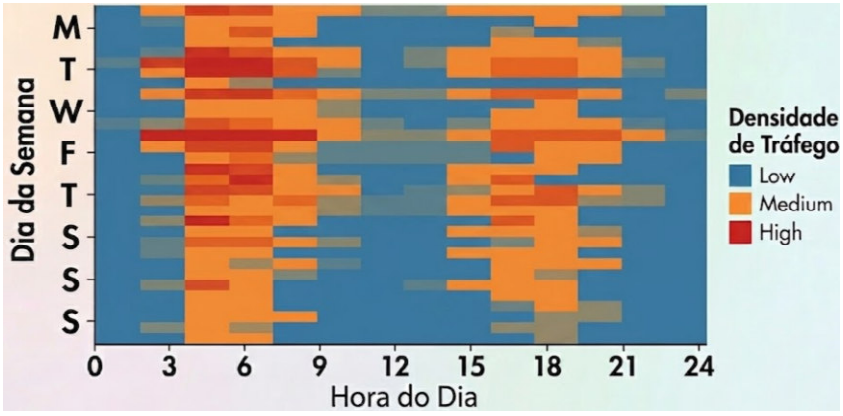


Técnicas baseadas em pixel

- Visualização dependente de consulta
  - Arranjo enfatiza relevância dos dados de acordo com determinada consulta
  - Envolve calcular distância entre consulta e dados, com arranjo de acordo com essa distância
    - Ex: Resultados mais relevantes situam-se em uma região específica (centro, topo, etc.), e instâncias são arranjadas em direção às extremidades

Técnicas baseadas em pixel

- Exemplo: visualização temporal de sensores de tráfego



Layout: visualização dos dias com movimento similar à segunda-feira

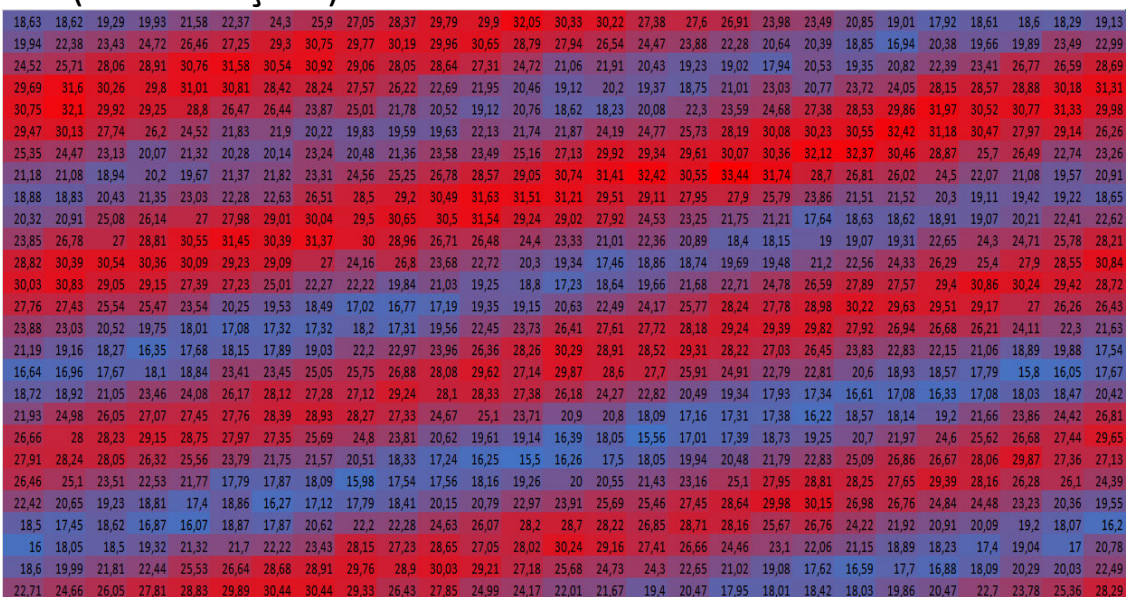
Técnicas baseadas em pixel

- Arranjo de dados unidimensionais: crítico para enxergar padrões
  - Unidimensional → bidimensional

- Maneira mais intuitiva: matriz bidimensional com “quebra de linha” para exibição
  - Problema: dados similares ficam distantes facilmente

Técnicas baseadas em pixel

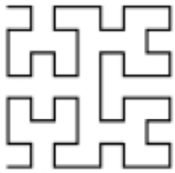
- Exemplo: temperaturas medidas a cada hora em 1 mês (729 medições)



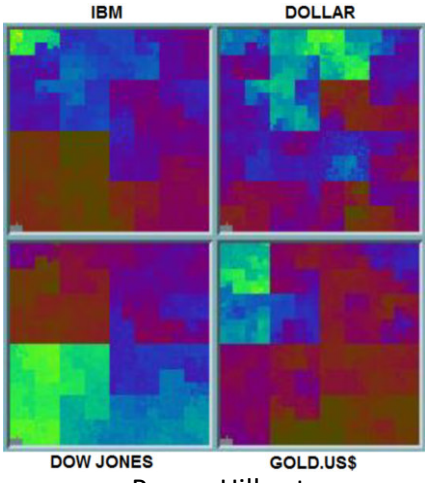
Técnicas baseadas em pixel

- Arranjo: prover melhor agrupamento
  - Instâncias relacionadas
  - Sentido semântico
- Curvas *space-filling*
  - Eliminação de “saltos bruscos”
  - Pontos próximos na sequência original tendem a permanecer próximos no espaço 2D
  - Generalização recursiva dos arranjos por linha e coluna: padrões de nível inferior agrupados para formar padrões de nível superior

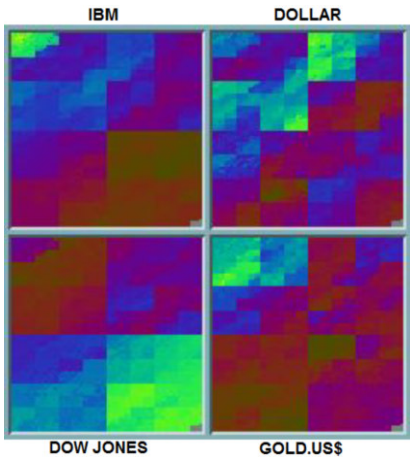
Curvas *Space Filling*







Peano-Hilbert



Morton

Retirado de [2]

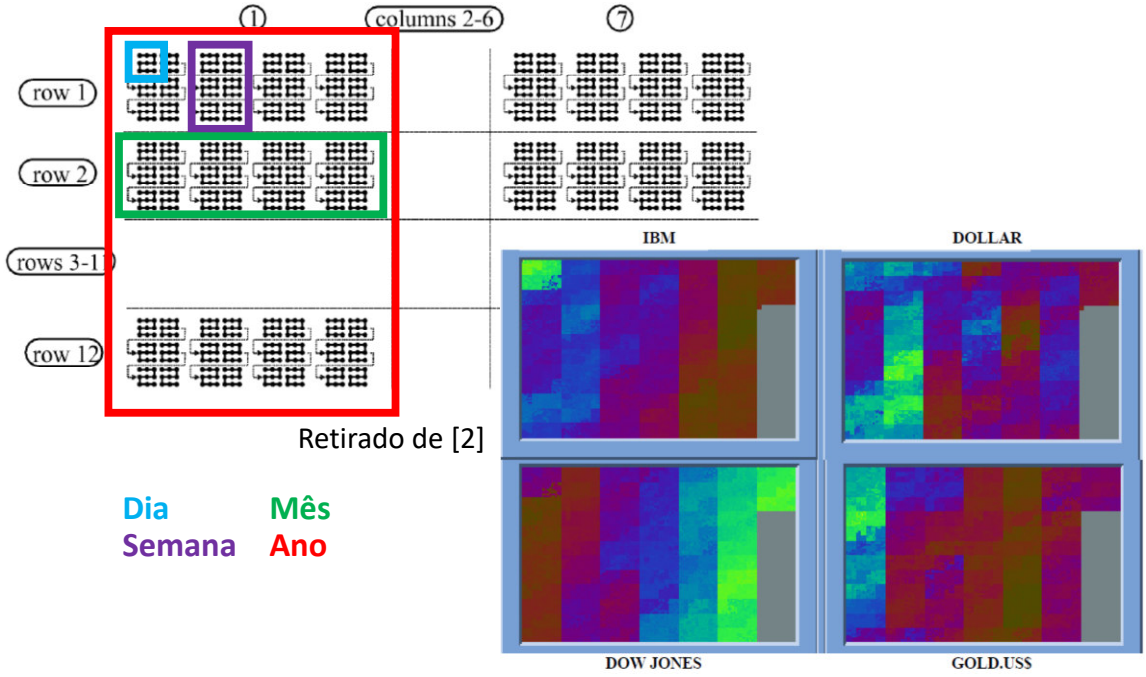
Curvas *Space Filling*

- Vantagem: Preservação da localidade (proximidade) espacial da imagem bidimensional original
- Visualização: mapeamento da distribuição unidimensional dos dados em duas dimensões
  - Itens próximos na distribuição unidimensional tendem a ficar próximos na representação bidimensional
- Como arranjo é definido em regiões de tamanho fixo, estrutura resultante não tem significado semântico

Padrões Recursivos

- Ideia: aproveitar as propriedades recursivas das abordagens *space filling*, mas permitindo ao usuário influenciar organização
  - Refletir estrutura inerente nos dados
- Exemplo: séries temporais diárias ao longo dos anos
  - Nível 1: dias
  - Nível 2: semanas
  - Nível 3: meses
  - Etc.

Padrões Recursivos



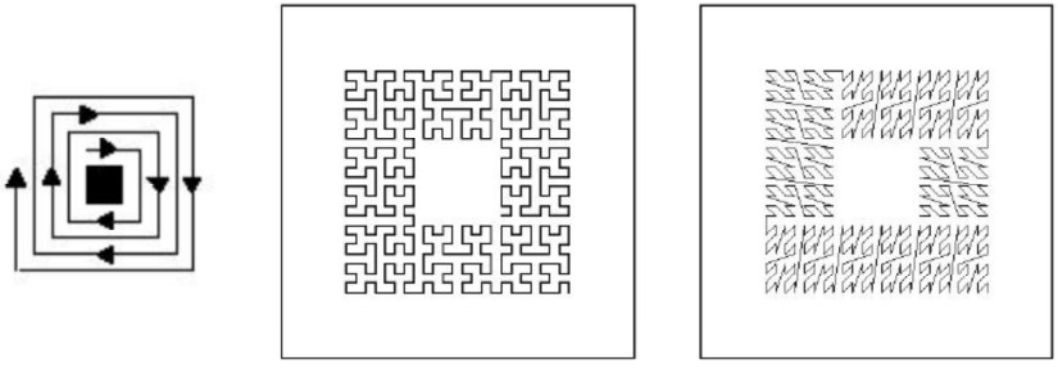
Retirado de [2]

Dia **Mês**
Semana **Ano**

$[(w_1, h_1) = (3, 3), (w_2, h_2) = (2, 3), (w_3, h_3) = (4, 1), (w_4, h_4) = (1, 12), (w_5, h_5) = (7, 1)]$

Curvas *Space Filling*

- Visualização dependente de consulta
  - Itens mais relevantes no centro
  - Valor do pixel: distância entre o item e o resultado de consulta (depende do tipo de dado e aplicação)



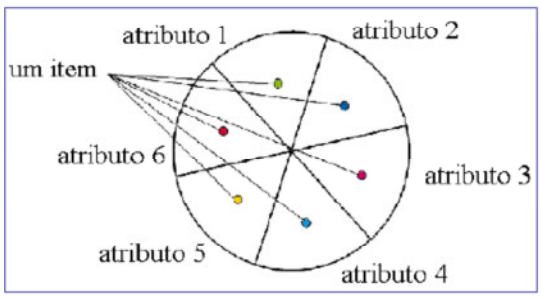
Retirado de [2]

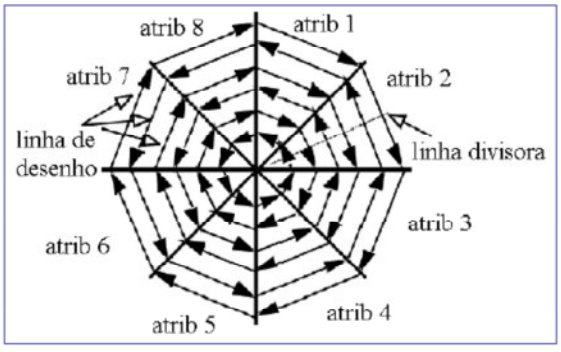
Técnicas baseadas em pixel

- Visualização de dados de tráfego usando técnica baseada em pixel:
  - https://social-glass.tudelft.nl/visualising-traffic-data/

Técnicas baseadas em pixel

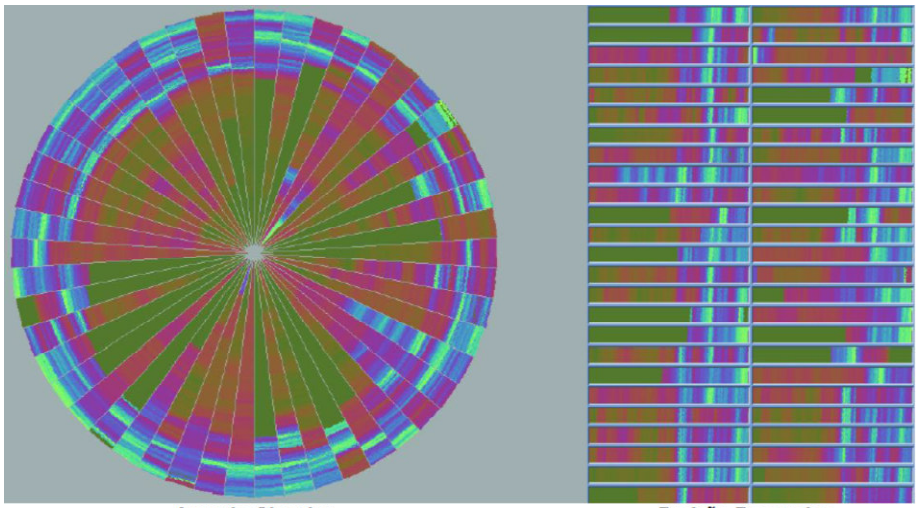
- Formato das janelas
  - Retangular: desvantagens
    - Dispersão de pixels de uma mesma instância na tela
    - Problema piora para dados com muitas dimensões
  - Alternativa: arranjo circular





Retirado de [3]

Arranjo Circular: Exemplo



Visualização de 50 ações da bolsa de Frankfurt (FAZ) durante 20 anos - 256.000 dados

Retirado de [2]

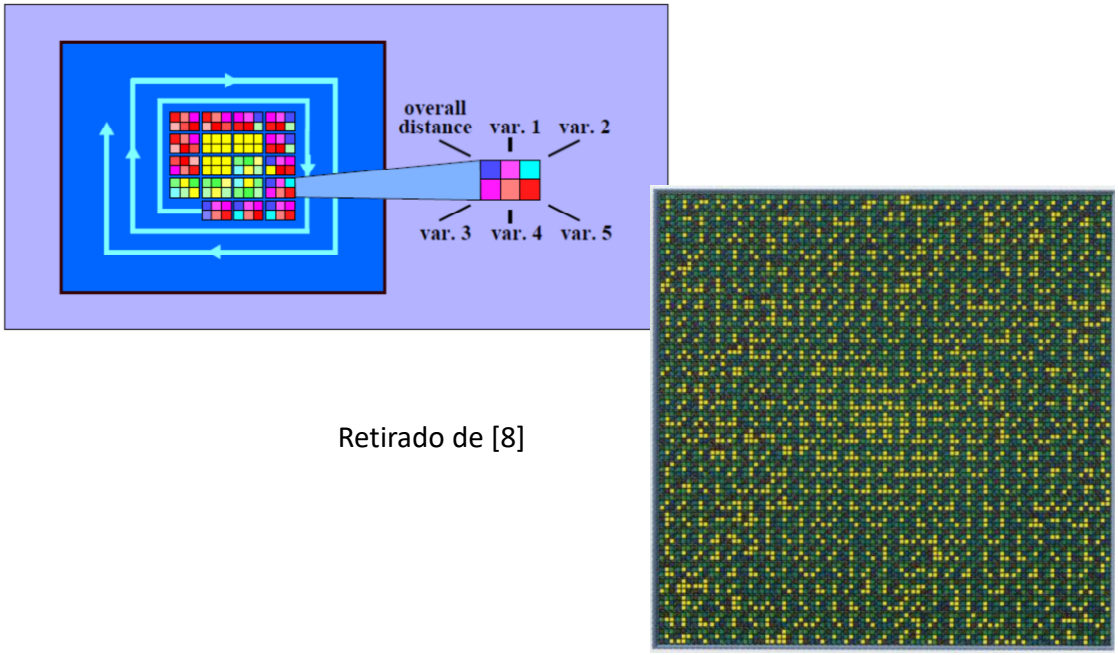
Ordenação das janelas

- Ordem de exibição das dimensões tem impacto expressivo na percepção de tendências
- Ordenação pode ser unidimensional (Arranjo circular) ou bidimensional (padrões recursivos)
- Alternativa: ordenação por similaridade
  - Definir uma medida de similaridade entre duas dimensões
  - Definir a ordem de similaridade: Problema NP-Completo
    - Usar heurísticas

Arranjo em grupo

- Ideia: agrupar todos os atributos de uma instância em uma janela
  - Janela: uma instância
  - Requer múltiplos pixels para cada atributo
    - “Superpixel”
    - Pelo menos 2x2 pixels para percepção
  - Pixels adicionais são necessários para desenhar uma borda dividindo as instâncias
  - Consequência: menos instâncias sendo visualizadas

Arranjo em grupo



Retirado de [8]

Transformações Geométricas

- Ideia: apresentar projeções dos dados de forma a encontrar correlações entre seus atributos

- Exemplos de técnicas populares
  - Coordenadas Paralelas
  - Matrizes de Dispersão
  - *Radial Visualization* (Radviz)

Coordenadas Paralelas

- Mapeamento do espaço *m*-dimensional para o plano bidimensional utilizando *m* eixos paralelos e equidistantes
  - Cada eixo corresponde a uma dimensão (atributo)
- Eixos são escalados linearmente do menor para o maior valor da dimensão correspondente
- Cada instância é representada por uma linha que intercepta cada um dos eixos
  - O local de interseção corresponde ao valor da dimensão correspondente ao eixo, para a instância em questão

Coordenadas Paralelas: Exemplo [4]

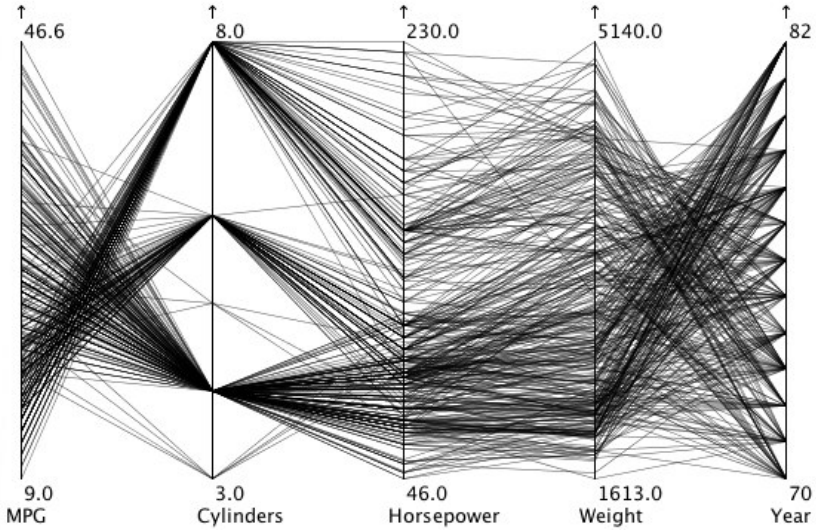
- Coleção carros

MPG	Cylinders	Horsepower	Weight	Year
15	8	170	3,563	70
14	8	160	3,609	70
15	8	150	3,761	70
14	8	225	3,086	70
24	4	95	2,372	70
22	6	95	2,833	70
18	6	97	2,774	70
21	6	85	2,587	70
27	4	88	2,130	70
26	4	46	1,835	70
25	4	87	2,672	70
24	4	90	2,430	70
25	4	95	2,375	70

Retirado de [4]

Coordenadas Paralelas: Exemplo [4]

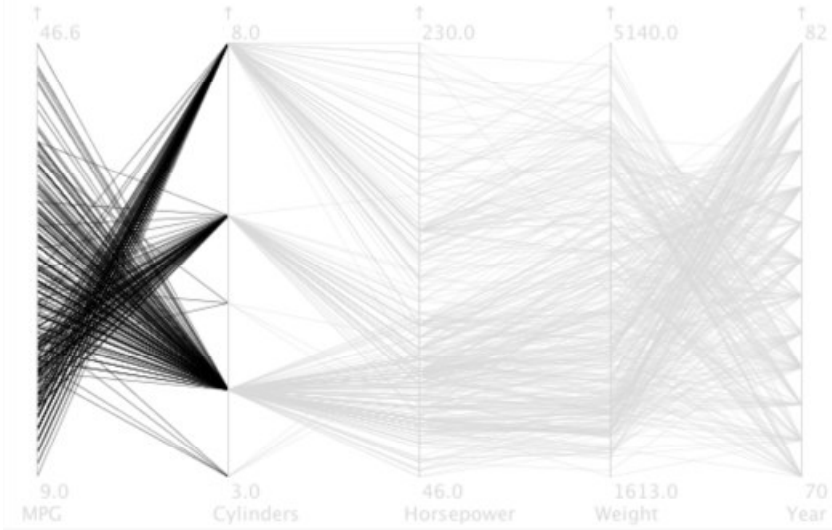
- Coleção carros



Retirado de [4]

Coordenadas Paralelas: Exemplo [4]

- Coleção carros



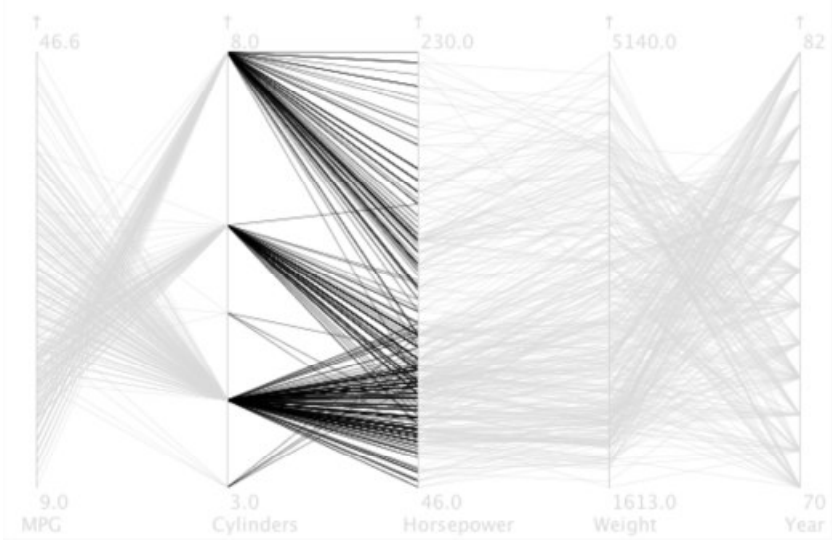
Retirado de [4]

Coordenadas Paralelas: Exemplo [4]

- No exemplo, o número de cilindros é uma informação inteira que assume poucos valores
- Dados dessa natureza, ou dados categóricos não são muito adequados para utilização da técnica
  - A técnica não mostra informações úteis nesse caso
- Relação ***MPG - cylinders***: é possível identificar que geralmente carros com 8 cilindros andam menos com um litro de combustível do que carros com 6 ou 4 cilindros
  - Correlação inversa: mais cilíndros → menos quilômetros por litro

Coordenadas Paralelas: Exemplo [4]

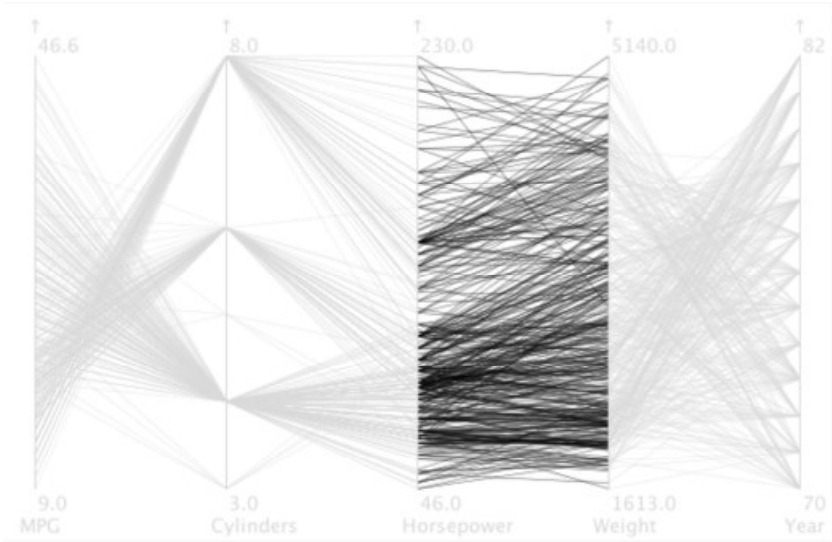
- Coleção carros



Retirado de [4]

Coordenadas Paralelas: Exemplo [4]

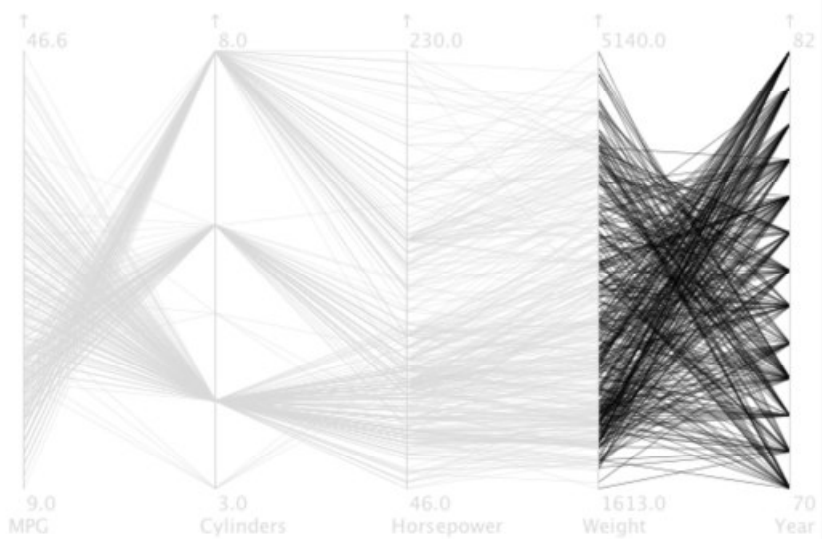
- Coleção carros



Retirado de [4]

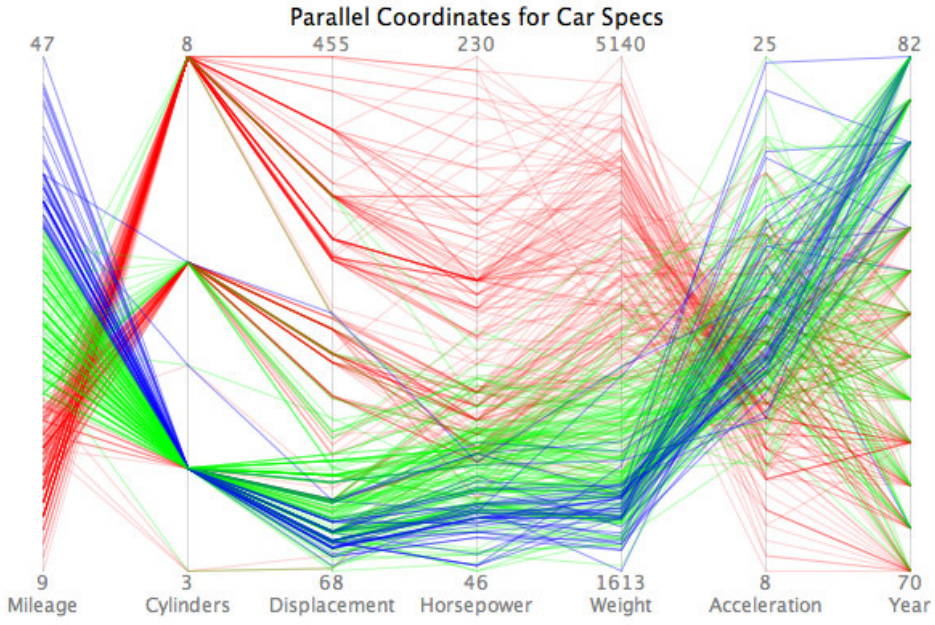
Coordenadas Paralelas: Exemplo [4]

- Coleção carros



Retirado de [4]

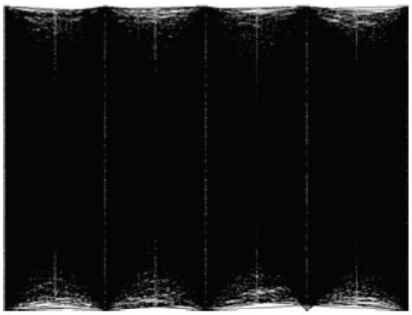
Coordenadas Paralelas



Wiley C., University of San Francisco

Coordenadas Paralelas

- Limitações
  - Quantidade de linhas pode causar muita sobreposição
    - Estimativa de no máximo 1000 linhas
  - Ordem dos eixos paralelos influencia na visualização



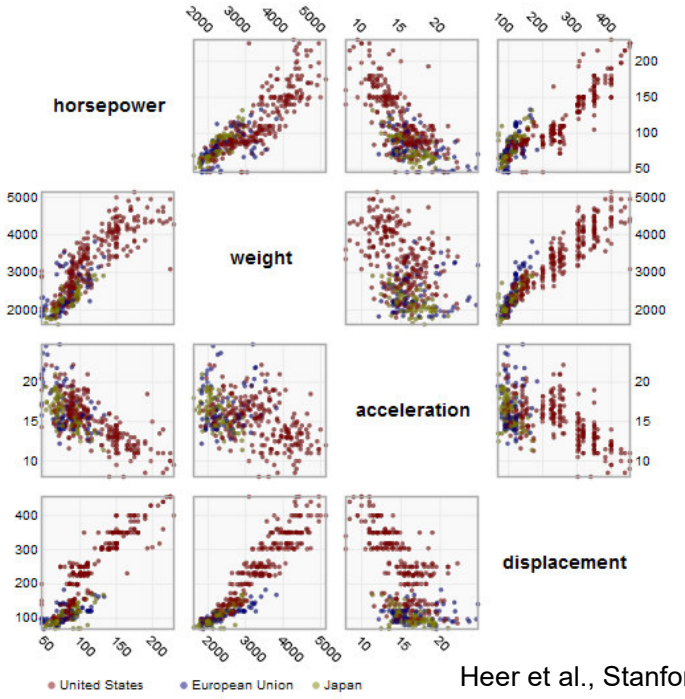
Coordenadas Paralelas de uma coleção de dados com 7500 instâncias, 5 atributos

  - Ex: http://www.parallelcoordinates.de/paco/

Matrizes de Dispersão

- Mapeamento do espaço *m*-dimensional para o plano bidimensional utilizando um conjunto de gráficos de dispersão (*scatterplots*)
- Cada gráfico de dispersão mostra o relacionamento entre os valores de dois atributos, sendo um mapeado para o eixo vertical e o outro para o eixo horizontal
- Foco na análise de correlação entre atributos, dado pelo padrão dos gráficos

Matrizes de Dispersão



Heer et al., Stanford University

Matrizes de Dispersão

- Limitações
  - Quantidade de atributos gera matriz muito grande
    - Muitas combinações
  - Organização das matrizes pode posicionar relacionamentos distantes uns dos outros, dificultando identificação de relacionamentos

RadViz

- Mapeamento do espaço *m*-dimensional para um plano de visualização que utiliza as leis físicas de Hookes
- Posição de cada ponto definida pela posição de *m* **âncoras**, normalmente arranjadas ao redor de uma circunferência
- Cada âncora é conectada a uma instância por uma "mola virtual" com grau de elasticidade proporcional ao valor da dimensão correspondente, para a instância em questão
- Instância é então mapeada para um ponto no qual todas as forças exercidas por todas as molas virtuais atingem o equilíbrio

RadViz

- Equilíbrio das forças exercidas pelas molas:

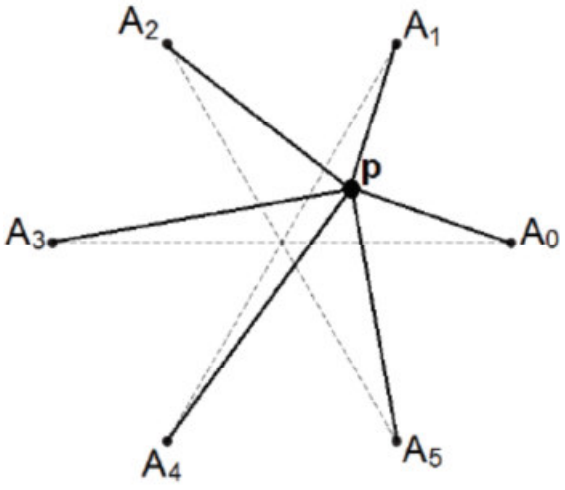
X: $[x_1,\ldots,x_m]$

Âncoras: $[A_1,\ldots,A_k]$

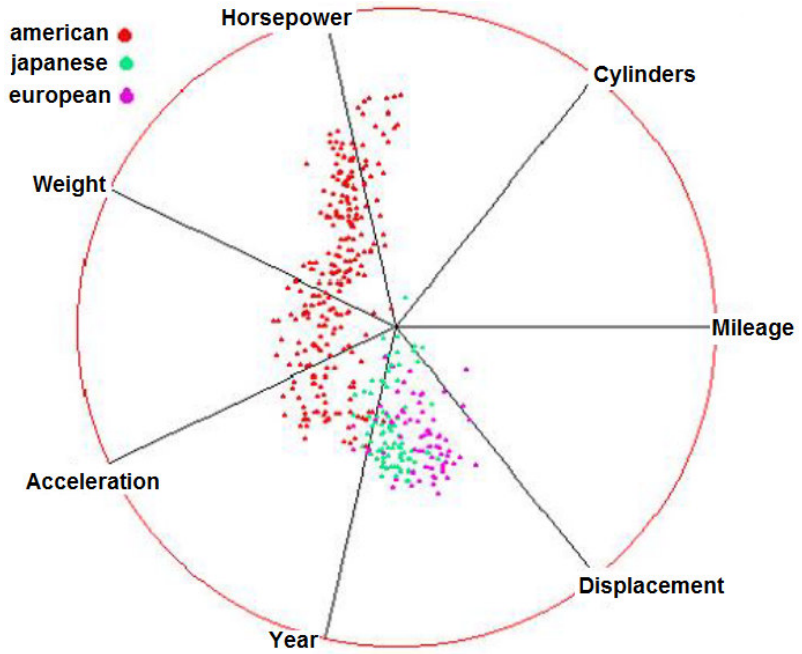
$$\sum_{j=1}^{k}(\vec{A}_j - \vec{p})x_j = 0$$

$p = [p_1, p_2]$

$$\vec{p} = \frac{\sum_{j=1}^{k}\vec{A}_j x_j}{\sum_{j=1}^{k} x_j}$$



RadViz

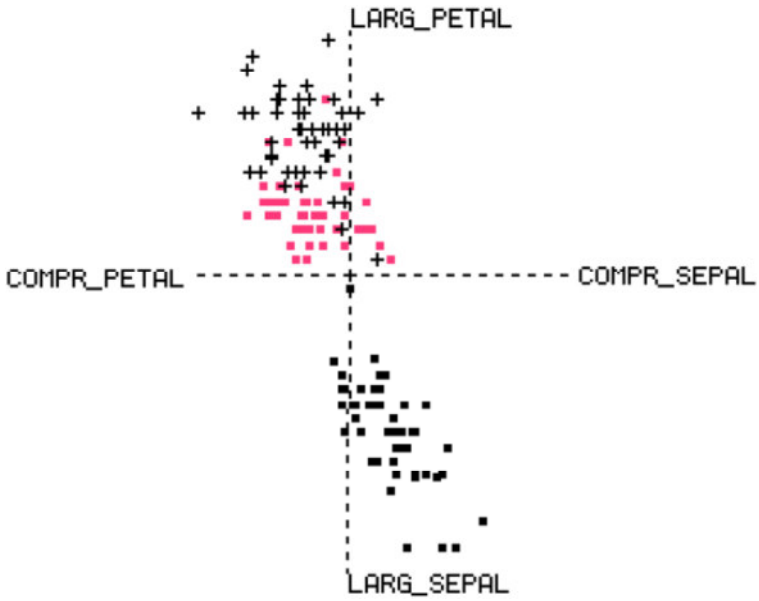


Hoffman, E., 1997

RadViz

- Características
  - Custo computacional baixo $O(mn)$
  - *Layout*: influências das dimensões nas instâncias
- Desvantagens
  - Sobreposição de pontos quando os valores dos atributos das instâncias correspondentes coincidem, ou são proporcionais
    - Ex.: $I_1 = [2, 2, 2, 2]$ e $I_2 = [6, 6, 6, 6]$
  - Ordenação das âncoras influencia no *layout*
    - Problema NP-completo

RadViz



RadViz para coleção de dados IRIS. Retirado de [3]

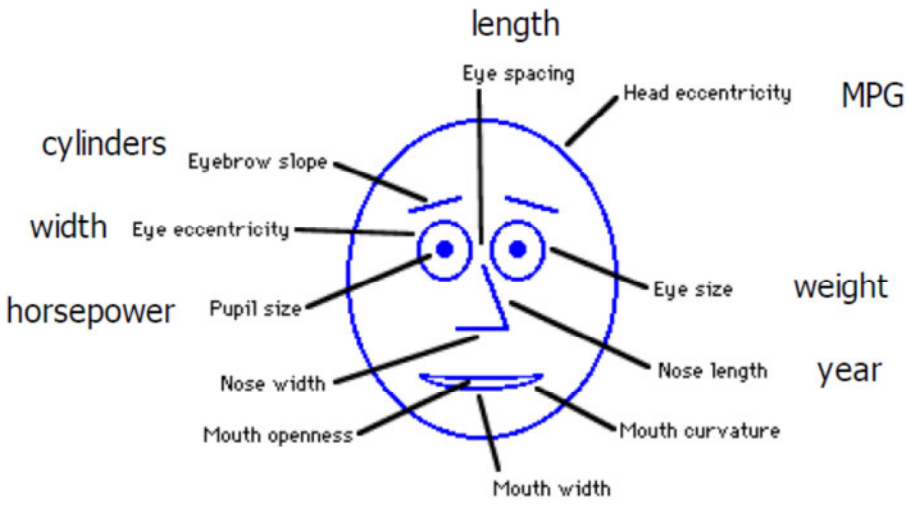
Ícones

- Ideia: mapear cada instância em um ícone
- Características do ícone, ou o próprio ícone, mapeiam valores dos atributos
  - Dois atributos podem ser mapeados em posições no plano
  - Demais atributos podem ser mapeados para cor, tamanho, forma, ou características específicas relacionadas aos ícones
- Exemplos de técnicas populares
  - Faces de Chernoff
  - *Stick Figures*
  - *Star Gliphs*

Faces de Chernoff

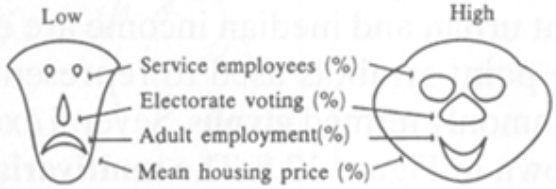
- Utiliza faces humanizadas para representar instâncias da coleção
- Duas das dimensões são mapeadas para a posição das faces
- O restante das dimensões é mapeado para características dos elementos componentes da face
  - Olhos
  - Nariz
  - Boca
  - etc.

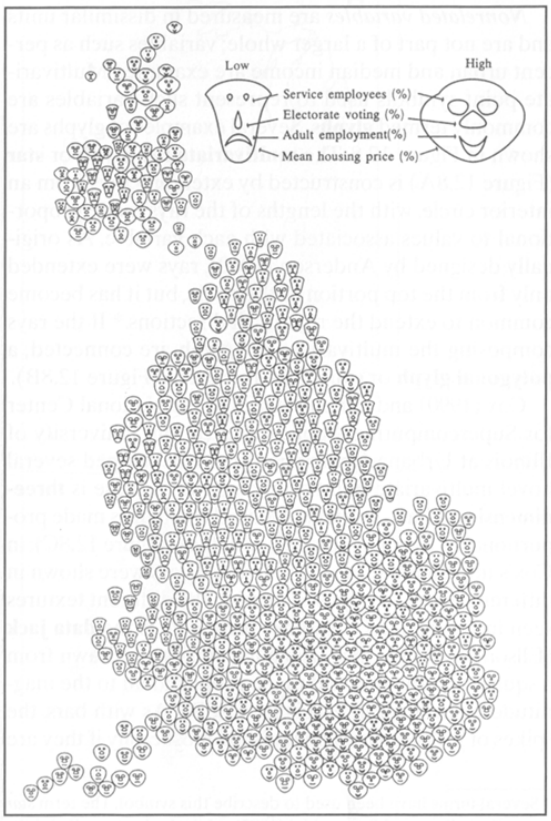
Faces de Chernoff



Retirado de [5]

Faces de Chernoff



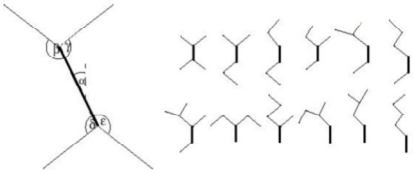


https://www.mat.ucsb.edu/~g.legrady/academic/courses/09w259/proj3/andres_applet/

Stick Figures

- Ícone: figura no estilo *stick*
- Semelhante ao método faces de Chernoff
  - Diferença: formato do ícone
  - Atributos restantes são mapeados em ângulos e comprimentos do ícone
- Se a distribuição dos dados é relativamente densa com relação às dimensões, o *layout* vai ressaltar padrões de textura que refletem as características dos dados: percepção pré-atentiva

Stick Figures: 1980 U.S. census



Retirado de [3]

- X e Y: renda e salário
- Demais atributos: ocupação, nível de educação, estado civil e gênero



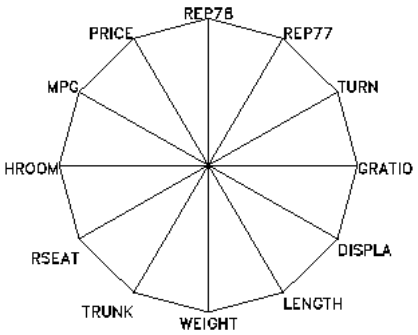
Retirado de [1]

Star Glyphs

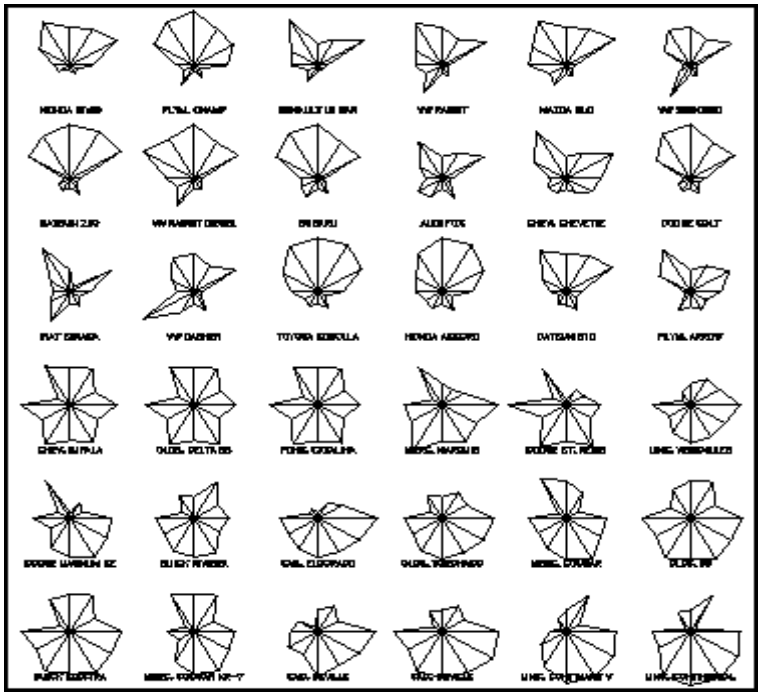
- Dados m-dimensionais são mapeados em m raios que emanam de um ponto formando ângulos iguais
- Um glifo para cada instância
- Comprimento do raio é proporcional ao valor da dimensão correspondente, para a instância em questão

http://euclid.psych.yorku.ca/SCS/sugi/sugi16-paper.html

Star Glyphs



Variable Assignment Key



Star Glyphs



Hierarquias

- Ideia: Dividir o espaço m-dimensional em supespaços apresentados de forma hierárquica

- Técnicas populares
  - *Dimensional stacking*
  - Treemap

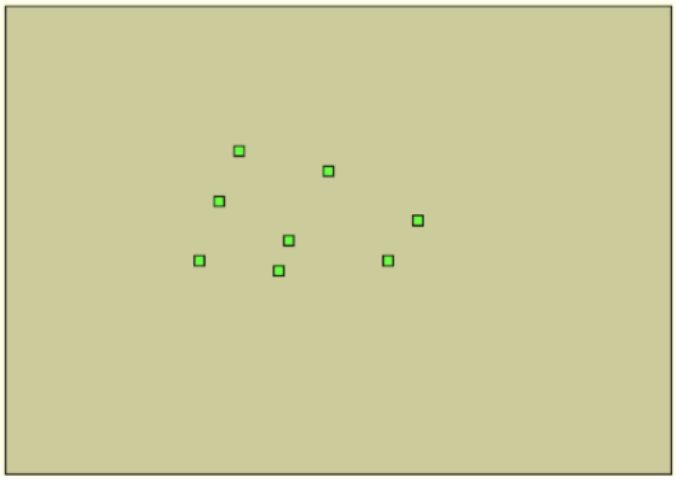
Dimensional stacking

- Posição das instâncias é definida pelo empilhamento de cada dimensão, uma dentro da outra

- Observações
  - Ordem de empilhamento influencia no resultado final
  - Dados não precisam ser naturalmente hierárquicos

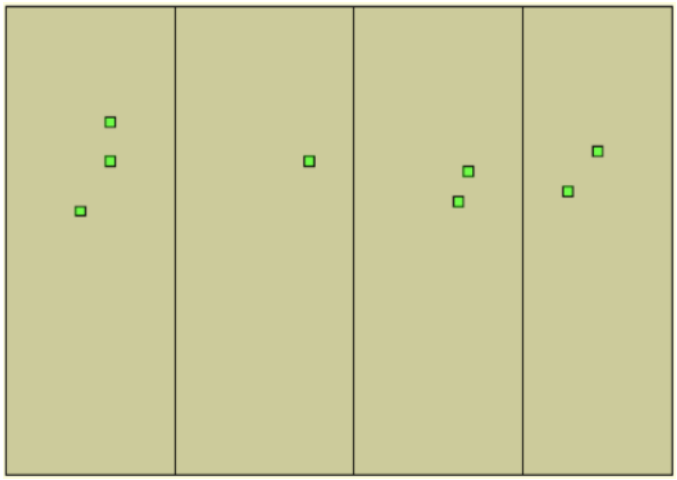
Dimensional stacking

- Processo (dados 4-dimensionais) [6]



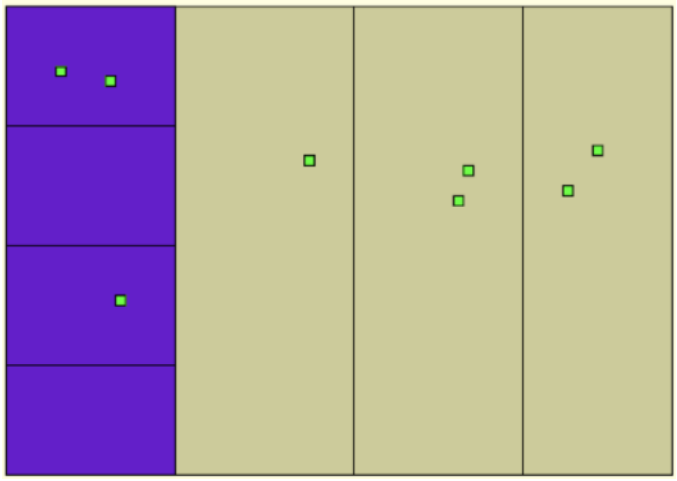
Dimensional stacking

- Processo (dados 4-dimensionais) [6]
  - Posicionamento de acordo com atributo 1



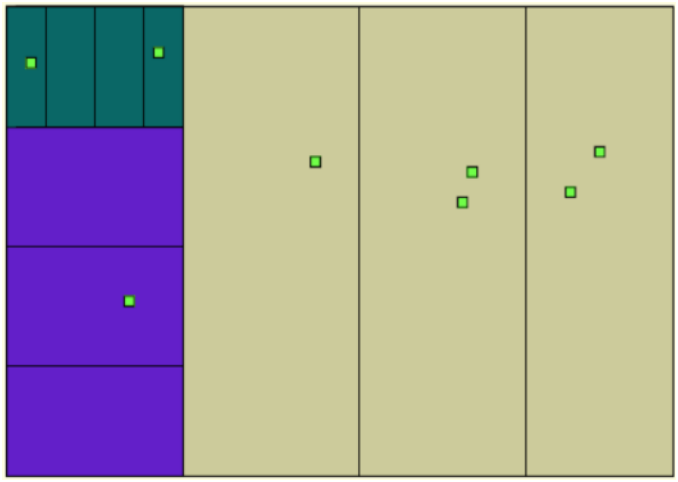
Dimensional stacking

- Processo (dados 4-dimensionais) [6]
  - Posicionamento de acordo com atributo 2



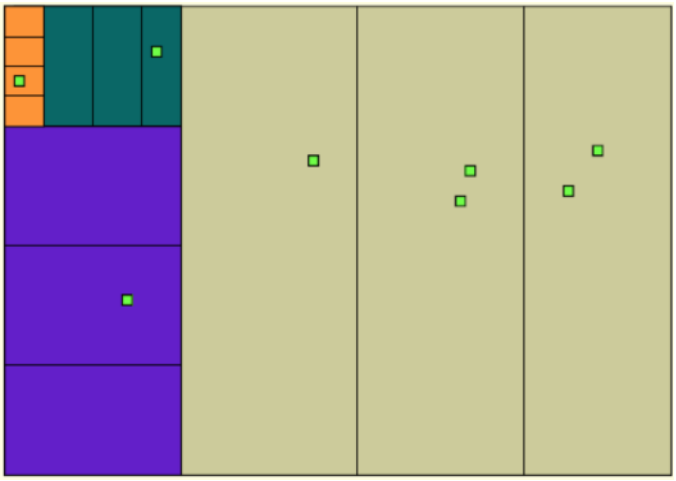
Dimensional stacking

- Processo (dados 4-dimensionais) [6]
  - Posicionamento de acordo com atributo 3



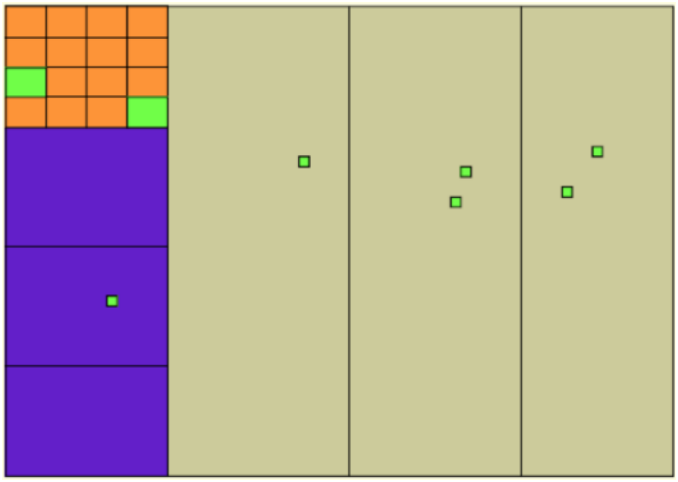
Dimensional stacking

- Processo (dados 4-dimensionais) [6]
  - Posicionamento de acordo com atributo 4



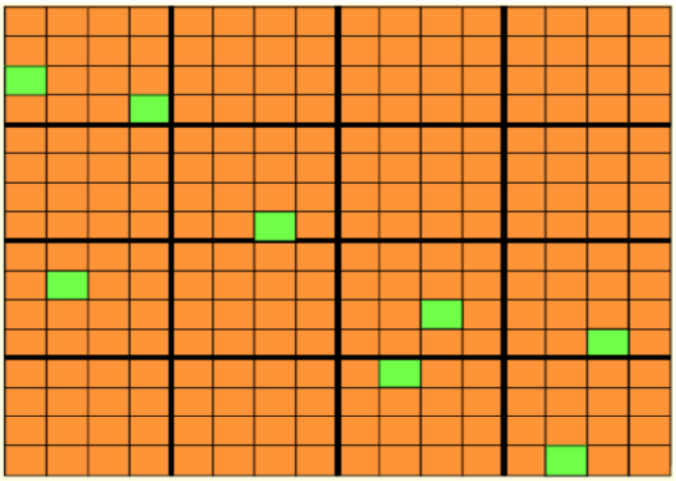
Dimensional stacking

- Processo (dados 4-dimensionais) [6]
  - Blocos fixados



Dimensional stacking

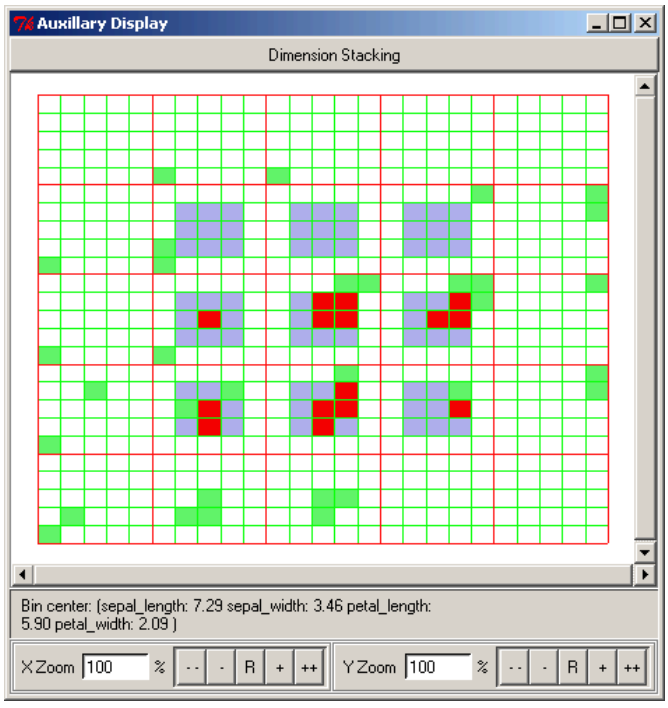
- Processo (dados 4-dimensionais) [6]
  - Resultado final



Dimensional stacking

Exemplo:

data set *Iris* [7]



Dimensional stacking

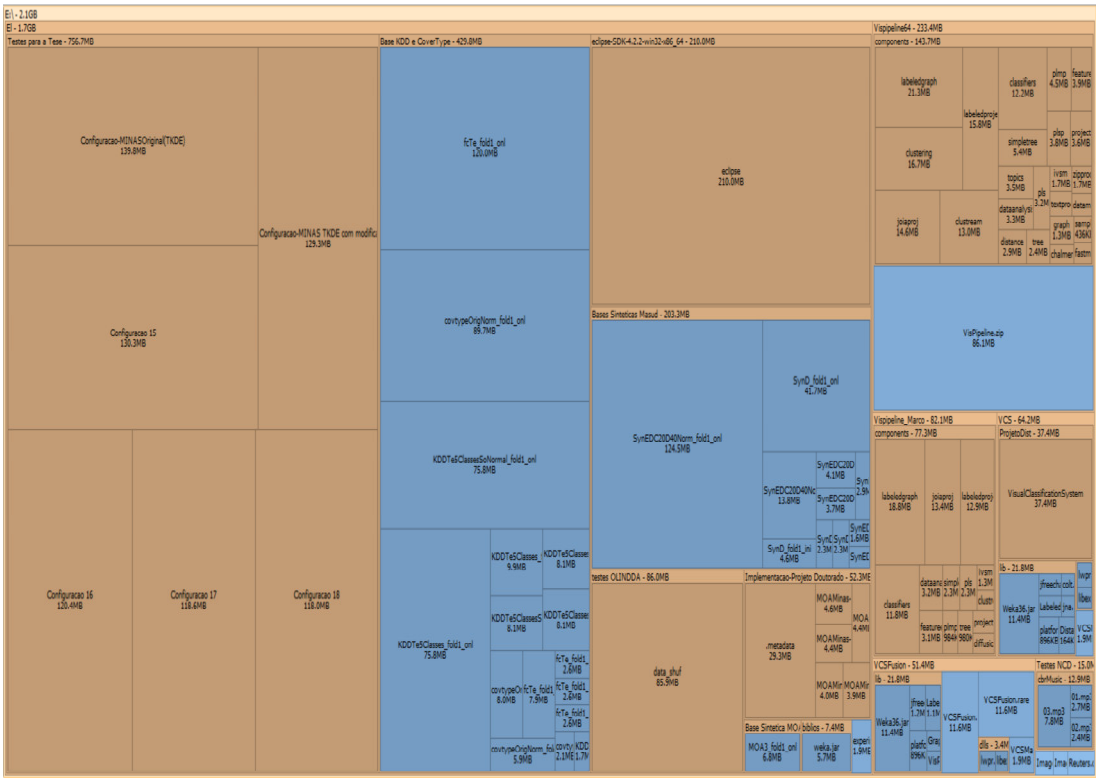
- Observações [3]
  - Atributos numéricos podem ter seus valores discretizados em intervalos
  - Atributos importantes devem ser mapeados nos níveis mais externos
  - Particularmente adequada para atributos ordinais de baixa cardinalidade

Treemap

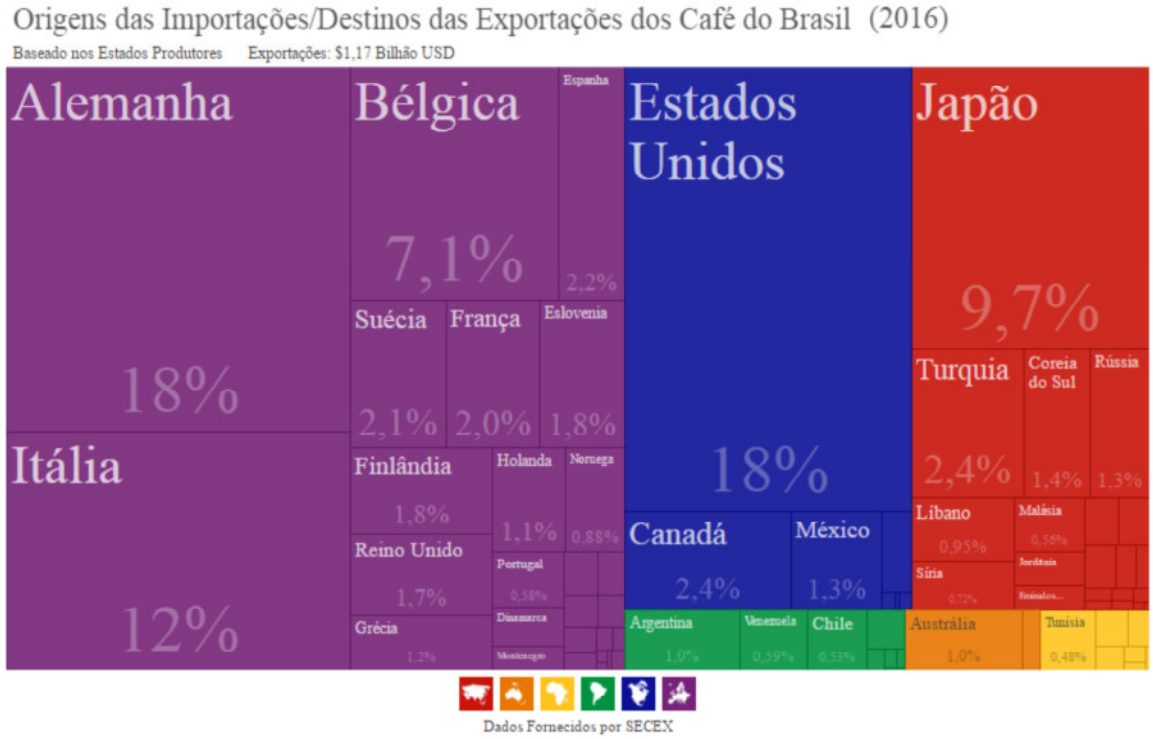
- Espaço de visualização particionado em um conjunto de áreas retangulares representando uma estrutura hierárquica
- Tamanho da área retangular proporcional ao valor de uma variável de uma instância ou grupo de instâncias
- Ideia: informações mais importantes com maior destaque
- Resultado: *layouts* com grande aproveitamento do espaço de visualização

Treemap

Gerado por SpaceSniffer



Treemap



DataViva

Técnicas baseadas em atributos

- Limitações
  - Dados de alta dimensionalidade/grandes volumes de dados: confusão visual (*Cluttering*)
  - Ordenação de atributos influencia muito no *layout*

Referências

1. Keim, D., Kriegel, H., Visualization techniques for mining large databases: A comparison. IEEE Transactions on Knowledge and Data Engineering, v. 8, n. 6, p. 923 – 938, 1996.
2. Keim, D., Designing Pixel-Oriented Visualization Techniques: Theory and Applications. IEEE Transactions on Visualization and Computer Graphics, v. 6, n. 1, pp. 59-78, 2000.
3. Oliveira, M. C. F, Técnicas de Visualização de Informação, notas de aula do curso de Visualização Computacional, Universidade de São Paulo - Campus São Carlos
4. Kosara, R., Parallel Coordinates, disponível em https://eagereyes.org/techniques/parallel-coordinates

Referências

5. Stasko, J., Multivariate VisualRepresentations 1, notas de aula da disicplina de Information Visualization da Georgia Institute of Technology, disponível em http://www.cc.gatech.edu/~stasko/7450/
6. Yang, J., Information Visualization, notas de aula da disciplina de *Information Visualization* da *University of North Carolina at Charlotte (UNCC)*, disponível em http://webpages.uncc.edu/jyang13/infovis2010/MultiVis.pdf
7. XmdvTool User's Manual, disponível em http://davis.wpi.edu/xmdv/docs/help_all.html
8. Keim, Daniel A. Pixel-oriented visualization techniques for exploring very large data bases., *Journal of Computational and Graphical Statistics 5.1* (1996): 58-77.